



Universidad Central de Venezuela
Facultad de Ciencias
Escuela de Computación

**Diseño e implementación de un modelo de mantenimiento asistido
por inteligencia artificial para una arquitectura de microservicios en
el sistema PortalAsig**

Trabajo Especial de Grado presentado ante la ilustre
Universidad Central de Venezuela por:
Br. Frank Ángel Ponte Delgado
Tutor: Prof. Walter Hernández



Universidad Central de Venezuela
Facultad de Ciencias
Escuela de Computación

ACTA DEL VEREDICTO

Quienes suscriben, miembros del Jurado designado por el Consejo de la Escuela de Computación, para examinar el Trabajo Especial de Grado presentado por el Bachiller Frank Ángel Ponte Delgado, C.I.: 23.950.509, titulado: "Diseño e implementación de un modelo de mantenimiento asistido por inteligencia artificial para una arquitectura de microservicios en el sistema *PortalAsig*", a los fines de cumplir con el requisito legal para optar por el título de Licenciado en Computación, dejan constancia de lo siguiente:

Leído el trabajo por cada uno de los Miembros del Jurado, se fijó el día 25 de septiembre de 2026 a las 11:00 horas para que su autor lo defendiera en forma pública y presencial en las instalaciones de la Escuela de Computación de la Facultad de Ciencias de la Universidad Central de Venezuela, mediante una presentación oral de su contenido, luego de lo cual respondió las preguntas formuladas, todo ello conforme a lo dispuesto en la Ley de Universidades y demás normativas vigentes de la Universidad Central de Venezuela. Finalizada la defensa pública del Trabajo Especial de Grado, el Jurado decidió aprobarlo.

En fe de lo cual se levanta la presente Acta, en Caracas a los veinticinco (25) días del mes de septiembre del año dos mil veintiséis (2026) dejándose también constancia de que actuó como coordinador del Jurado el Profesor Tutor Walter Hernández.

Prof. Walter Hernández
Tutor

Prof. Francisco Moreno
Jurado Principal

Prof. Moisés Berenguer
Jurado Principal

Agradecimientos

A la Universidad Central de Venezuela y a la Facultad de Ciencias, por formarme como profesional y por brindarme la oportunidad de contribuir, mediante este trabajo, a un sistema que sirve a su comunidad académica.

A mi tutor, Prof. Walter Hernández, por su orientación constante, su paciencia y su compromiso con la mejora continua de PortalAsig a lo largo de los años.

A los docentes y colaboradores que mantuvieron vivo el sistema durante más de una década, y cuyo esfuerzo colectivo motivó e inspiró este trabajo.

A mis padres Ángel y Sandra y a mi hermano Christian. Su apoyo y ejemplo motiva mis días, los amo.

A mis amigos, por apoyarme y acompañarme en este largo proceso.

Resumen

El sistema PortalAsig opera desde el año 2016 sobre una arquitectura monolítica que acumuló seis años de deuda técnica sin proceso sistemático de mantenimiento, en un contexto sin equipo de desarrollo de tiempo completo y con colaboradores académicos temporales. Esta situación generó un grado de acoplamiento que dificultaba cualquier intervención y hacía depender el sistema del conocimiento tácito de cada mantenedor.

El presente trabajo documenta el rediseño del backend hacia una arquitectura de microservicios que descompone el sistema en dominios acotados e independientes —UAA (gestión de identidad), Site (sitios académicos) y Notify (notificaciones)— cada uno con base de datos propia y ciclo de despliegue autónomo. El frontend heredado fue adaptado para operar como cliente distribuido mediante Vuex modular, guards de navegación, autenticación OAuth2/JWT y clientes Axios multi-servicio. Sobre este ecosistema se implementaron técnicas sistemáticas de aseguramiento de calidad que abarcan todo el ciclo de vida del código —desde el análisis estático y la integración continua hasta las pruebas end-to-end y la medición de cobertura— y se instrumentó observabilidad distribuida para consolidar métricas y logs en un panel centralizado.

Sobre esta infraestructura se construyó el servicio PAIMA (PortalAsig Intelligent MAPE-K), que ejecuta un ciclo de autogestión del mantenimiento donde las fases de Análisis y Planificación se delegan a un modelo de inteligencia artificial. PAIMA monitorea el ecosistema, detecta anomalías, clasifica incidencias y propone acciones de remediación que el operador humano evalúa y aprueba.

La validación mediante pruebas de integración, validación end-to-end y simulación de caos demostró que el ecosistema aísla fallos, mantiene métricas objetivas de calidad y reduce la carga cognitiva del mantenedor. El resultado es un sistema desacoplado, observable y autogestionado que puede ser mantenido por colaboradores académicos temporales sin depender del conocimiento tácito.

Palabras clave: arquitectura de microservicios, mantenimiento de software, integración continua, observabilidad distribuida, computación autónoma, MAPE-K, inteligencia artificial, autogestión del mantenimiento.

Índice general

Agradecimientos	2
Resumen	3
Introducción	9
1. Planteamiento del problema	12
1.1. Justificación	13
1.2. Objetivo General	14
1.3. Objetivos Específicos	14
2. Marco Teórico	16
2.1. Evolución de los Paradigmas Web	16
2.1.1. De la Web 1.0 a la Web 3.0	16
2.1.2. Web 3.0: Distribución, Autonomía e Inteligencia Artificial	17
2.2. Arquitecturas de Software	18
2.2.1. Arquitecturas Monolíticas	18
2.2.2. Arquitecturas Basadas en Microservicios	19
2.2.3. Comparación entre Arquitecturas Monolíticas y Microser-	19
vicios	19
2.3. Tecnologías para el Desarrollo y Operación de Microservicios . .	20
2.3.1. Contenedores y Orquestación	20
2.3.2. Framework y Construcción	20
2.3.3. Seguridad y Comunicación	22
2.3.4. Persistencia	23
2.3.5. Observabilidad Distribuida	24
2.3.6. Calidad de Software y Testing	24
2.3.7. Documentación y Frontend	26
2.3.8. Modelos de Lenguaje de Gran Escala y Locales	27
2.4. Mantenimiento de Software	28
2.4.1. Tipos de Mantenimiento	28
2.4.2. Retos en Sistemas Distribuidos	29
2.4.3. Prácticas Modernas de Aseguramiento de Calidad	29
2.4.4. Ingeniería del Caos	29

2.5.	Computación Autonómica	30
2.5.1.	Concepto y Propiedades Self-CHOP	30
2.6.	Modelo MAPE-K	31
2.6.1.	Componentes del Ciclo	31
2.6.2.	De MAPE-K a la Integración de Inteligencia Artificial	31
2.7.	Sistemas Auto-adaptativos	32
2.8.	Inteligencia Artificial aplicada al Mantenimiento de Software	33
2.9.	AIOps y Automatización de Operaciones	33
2.10.	Integración de IA en Arquitecturas de Microservicios	33
3.	Marco Aplicativo	35
3.1.	Migración del Backend a una Arquitectura de Microservicios	35
3.1.1.	Análisis del Sistema Monolítico Legacy	35
3.1.2.	Diseño de la Arquitectura de Microservicios	37
3.1.3.	Stack Tecnológico del Backend	39
3.1.4.	Técnicas de Mantenimiento de Software Implementadas	42
3.1.5.	Despliegue, Gestión y Migración de Datos	45
3.2.	Comparativa Cualitativa: Monolito vs. Microservicios	46
3.3.	Servicio PAIMA — Autogestión del Mantenimiento Asistido por IA	48
3.3.1.	Motivación y Contexto	48
3.3.2.	Arquitectura Interna de PAIMA	49
3.3.3.	Fase Monitor: Recolección de Datos Operativos	50
3.3.4.	Fase Analyze y Plan: Asistencia con Inteligencia Artificial	51
3.3.5.	Fase Execute: Automatización y Notificación	51
3.3.6.	Fase Knowledge: Registro de Incidentes y Retroalimentación	52
3.4.	Adaptación del Frontend a la Arquitectura Distribuida	52
3.4.1.	Diagnóstico del Frontend Legacy	52
3.4.2.	Reestructuración Arquitectónica	53
3.4.3.	Migración de Autenticación	53
3.4.4.	Integración con los Microservicios	54
4.	Pruebas y Resultados	56
4.1.	Metodología y Entorno de Pruebas	56
4.2.	Pruebas de Integración y Cobertura de Código	57
4.2.1.	Estrategia de Pruebas de Integración	57
4.2.2.	Cobertura de Código con JaCoCo	58
4.3.	Pruebas End-to-End	62
4.3.1.	Selección de Herramienta y Diseño de Flujos	63
4.3.2.	Resultados de Ejecución	63
4.3.3.	Validación de la Arquitectura Frontend Adaptada	65
4.4.	Benchmarking de Rendimiento	67
4.4.1.	Diseño del Experimento	67
4.4.2.	Análisis de Diseño Experimental	68
4.4.3.	Resultados del Benchmarking	69
4.5.	Simulación de Caos y Recuperación Asistida	70
4.5.1.	Diseño del Escenario	71

4.5.2. Comportamiento Observado	71
4.5.3. Interfaz de Operación del Sistema de Autogestión	72
4.5.4. Lecciones del Experimento	75
4.6. Análisis Comparativo Global	76
5. Conclusiones y Recomendaciones	78
5.1. Conclusiones	78
5.2. Limitaciones	79
5.3. Recomendaciones y Trabajo Futuro	80
Glosario	84

Índice de figuras

3.1. Diagrama entidad-relación simplificado del modelo de datos monolítico, mostrando la tabla <code>site</code> como núcleo con sus dieciocho relaciones hacia entidades dependientes.	38
3.2. Arquitectura del ecosistema de microservicios de PortalAsig, mostrando el proxy Nginx, el Config Server, los cuatro microservicios (UAA, Site, Notify, PAIMA), sus bases de datos MySQL aisladas, el proveedor LLM externo, el stack de observabilidad (Prometheus, Loki, Grafana) y las conexiones de monitoreo de PAIMA hacia los endpoints <code>/actuator/health</code> de cada microservicio, todo desplegado sobre la red virtual de Docker Compose.	40
3.3. Estructura de directorios de migraciones Flyway en un microservicio.	42
3.4. Extracto del script de migración inicial <code>V1.0.0.00__init.sql</code> del servicio Site, mostrando la definición de tablas con sentencias <code>CREATE TABLE</code> y comentarios de columnas.	43
3.5. Diagrama de herencia de dependencias Maven.	44
3.6. Exploración de logs con Grafana y Loki durante el arranque del ecosistema de microservicios.	45
3.7. Modelo de datos distribuido del ecosistema: esquemas aislados por servicio, con claves foráneas reales dentro de cada dominio y referencias lógicas (sin clave foránea) entre dominios.	46
3.8. Diagrama de clases de PAIMA mostrando los paquetes del ciclo MAPE-K.	50
4.1. Pull request bloqueado mientras el workflow de GitHub Actions se encuentra en ejecución. El check “Build and Verify Services” aparece como requerido y el merge permanece deshabilitado hasta su finalización.	59
4.2. Ejecución del workflow de GitHub Actions para el servicio Site, mostrando los pasos de compilación, pruebas de integración y verificación de cobertura.	60
4.3. Pull request desbloqueado tras la finalización exitosa del workflow. El check “Build and Verify Services” aparece como requerido y exitoso, habilitando la opción de merge.	61

4.4. Interfaz Swagger UI del servicio Site, mostrando los endpoints REST documentados automáticamente.	62
4.5. Vista general del dashboard de Cypress, mostrando la cobertura de las funcionalidades de la aplicación a través de pruebas de automatización end-to-end.	64
4.6. Secuencia de pasos del flujo de autenticación OAuth2/JWT validada mediante Cypress: obtención de token anónimo, login con credenciales, persistencia en cookies y refresco automático.	66
4.7. <i>Panel de observabilidad de Grafana durante la ejecución del benchmark sobre el servicio Site: se aprecian el throughput sostenido de aproximadamente 300 peticiones por segundo, la latencia media del endpoint de lectura y la ausencia de respuestas de error (2xx al cien por ciento) bajo cincuenta usuarios virtuales</i>	70
4.8. Panel de control de PAIMA durante la simulación de caos, con la alerta P1 del servicio Site pendiente de aprobación.	72
4.9. Listado de alertas autonómicas priorizadas visibles para el administrador.	73
4.10. Correo electrónico autogenerado por PAIMA al detectar la caída del servicio Site durante la simulación de caos, recibido por el administrador con el diagnóstico de la IA, la acción sugerida y el enlace al panel de alertas.	74
4.11. Vista de detalle de un incidente P1 en PAIMA, consolidando métricas, logs y recomendación de la IA.	74
4.12. Interacción del administrador con el agente de IA para refinar el diagnóstico.	75
4.13. Aprobación y ejecución de la acción de auto-reparación mediante el asistente IA.	76

Introducción

El sistema PortalAsig fue desarrollado en el año 2016 para la gestión académica de la Facultad de Ciencias de la Universidad Central de Venezuela. Inicialmente concebido como una plataforma centralizada que facilitara la comunicación entre docentes y estudiantes, el sistema ha evolucionado durante más de una década mediante modificaciones incrementales que expandieron su funcionalidad sin alterar su arquitectura fundamental. El frontend del sistema fue rediseñado en el año 2020 por Vásquez Balza [1], quien migró la interfaz de usuario desde Angular hacia Vue.js bajo un enfoque orientado a la mantenibilidad. Este rediseño mejoró la organización del código cliente, sentó las bases para una evolución controlada de la capa de presentación y demostró que un rediseño arquitectónico bien planificado puede extender la vida útil de un sistema sin reescribirlo por completo. No obstante, el backend del sistema permaneció basado en una arquitectura monolítica que acumuló, durante seis años consecutivos, una deuda técnica creciente sin proceso sistemático de mantenimiento.

El backend de PortalAsig permanece tecnológicamente estancado en una arquitectura monolítica que concentra todas las responsabilidades del negocio —autenticación de usuarios, gestión de asignaturas, creación de sitios académicos, administración de evaluaciones, foros, entregas de archivos, envío de correos y encuestas— dentro de un único proceso desplegable. La ausencia de personal de desarrollo de tiempo completo dedicado al sistema impide actualizar esta arquitectura: los colaboradores académicos temporales que asumen el mantenimiento deben operar sobre una base de código de difícil comprensión, sin documentación exhaustiva ni procesos formales de transferencia de conocimiento. A medida que el sistema creció en funcionalidad, la base de código se densificó progresivamente, generando acoplamiento entre dominios que originalmente eran independientes. La ausencia de pruebas automatizadas, de mecanismos de validación de cambios y de herramientas de observabilidad convirtió cada modificación en un ejercicio de alto riesgo, donde la introducción de un cambio local podía afectar funcionalidades aparentemente no relacionadas.

El contexto operativo agrava esta problemática. El sistema carece de un equipo de desarrollo y operaciones de tiempo completo; el soporte técnico recurrente proviene del grupo docente y las mejoras se originan en colaboradores académicos temporales —estudiantes de Trabajo Especial de Grado, de seminario o de servicio comunitario— que permanecen en el proyecto entre uno y dos semestres. Esta rotación perpetua —un fenómeno documentado en la literatura de ingeniería

de software como rotación de personal [2]— implica que el conocimiento tácito acumulado sobre el código, la infraestructura y los procesos de despliegue se pierde cada vez que un colaborador concluye su período, obligando al siguiente a reconstruirlo, al menos parcialmente, sobre una base de código de difícil comprensión. La infraestructura donde se aloja el monolito opera bajo una modalidad *on-premise*, sin acceso a servicios de computación en la nube ni a un equipo de DevOps dedicado. El despliegue se realiza de forma manual mediante conexión directa al servidor. En estas condiciones, cualquier herramienta adicional que requiera infraestructura propia, configuración compleja o mantenimiento continuo constituye un pasivo técnico que el siguiente colaborador deberá asumir sin garantía de transferencia de conocimiento.

Frente a esta situación, se diseñaron e implementaron dos líneas de transformación. La primera consistió en el rediseño del backend hacia una arquitectura de microservicios que descompone el sistema en dominios acotados e independientes—UAA (gestión de identidad), Site (sitios académicos) y Notify (notificaciones)—cada uno con su propia base de datos, su esquema de versionado y su ciclo de despliegue autónomo. Esta transformación elimina el acoplamiento referencial entre dominios del modelo monolítico y habilita el aislamiento de fallos, de modo que la caída de un servicio no compromete la estabilidad del ecosistema completo. Sin embargo, la migración a microservicios introduce una complejidad operativa inherente a los sistemas distribuidos: múltiples procesos, múltiples bases de datos, latencia de red, tolerancia a fallos y monitoreo distribuido.

La segunda línea de transformación adaptó el frontend heredado para operar como cliente de esa nueva arquitectura distribuida: se reestructuró el store Vuex en módulos por dominio, se implementaron guards de navegación con siete niveles de permisos, se reemplazó la autenticación propietaria por un flujo OAuth2/JWT con cookies y refresh token, y se configuraron múltiples instancias de Axios que reflejan la topología de los microservicios (UAA, Site, PAIMA).

Para afrontar la complejidad operativa del ecosistema distribuido, se implementaron técnicas sistemáticas de mantenimiento de software que abarcan todo el ciclo de vida del código. Se incorporaron mecanismos de validación automatizada que analizan el estilo del código antes de su fusión, ejecutan pruebas sobre bases de datos reales y miden la cobertura de las mismas. Se diseñaron pruebas que simulan flujos completos del usuario final sobre la interfaz, verificando que las capas de presentación, aplicación y persistencia operen de forma coordinada. Asimismo, se instrumentaron mecanismos de observabilidad distribuida que recolectan métricas de rendimiento, agregan registros de ejecución y visualizan correlaciones entre eventos. Estas técnicas no son complementos optativos: son la condición previa que permite a un colaborador académico temporal comprender el estado del sistema, detectar anomalías antes de que afecten a los usuarios y realizar cambios con confianza, reduciendo la dependencia del conocimiento tácito.

Sobre esta infraestructura se construyó el servicio PAIMA (PortalAsig Intelligent MAPE-K) [3], que ejecuta un ciclo de autogestión del mantenimiento donde las fases de Análisis y Planificación se delegan a un modelo de inteligencia artificial. PAIMA monitorea el ecosistema, detecta anomalías, clasifica

incidencias y propone acciones de remediación que el operador humano evalúa y aprueba. La validación mediante pruebas de integración, validación end-to-end y simulación de caos demostró que el ecosistema aísla fallos, mantiene métricas objetivas de calidad y reduce la carga cognitiva del mantenedor. El resultado es un sistema desacoplado, observable y autogestionado que puede ser mantenido por colaboradores académicos temporales sin depender del conocimiento tácito.

El presente documento se organiza en cinco capítulos. El Capítulo 1 plantea el problema, justifica la necesidad de transformación y establece los objetivos general y específicos del trabajo. El Capítulo 2 presenta el marco teórico, abordando las arquitecturas monolíticas y de microservicios, el modelo MAPE-K, la computación autónoma, la observabilidad en sistemas distribuidos y las tendencias convergentes que sustentan la autogestión del mantenimiento asistida por inteligencia artificial. El Capítulo 3 documenta el desarrollo aplicativo: el análisis del monolito legacy, el diseño de la arquitectura de microservicios, las técnicas de mantenimiento implementadas y la arquitectura del servicio PAIMA. El Capítulo 4 describe la estrategia de pruebas diseñada, los escenarios ejecutados y los resultados obtenidos en cobertura de código, validación end-to-end, simulación de caos y análisis comparativo. El Capítulo 5 cierra el trabajo con las conclusiones, las limitaciones observadas y las líneas de evolución propuestas para el ecosistema.

Capítulo 1

Planteamiento del problema

El sistema PortalAsig, desarrollado para la gestión académica en la Facultad de Ciencias de la Universidad Central de Venezuela, se ejecuta desde el año 2016 sobre una arquitectura monolítica que concentra todas sus funcionalidades —autenticación de usuarios, gestión de asignaturas, sitios académicos, evaluaciones, foros, entregas de archivos, envío de correos y encuestas— en un único proceso Node.js. En este backend, el archivo `site.js`, ubicado en el directorio `api/controllers/`, alcanza 3.629 líneas de código que gestionan dieciocho dominios de negocio distintos, desde bibliografías hasta calificaciones, sin mecanismo de aislamiento que impida que un fallo en un módulo comprometa la estabilidad de la aplicación completa. La entidad `Site`, definida en el modelo `api/models/site.js`, declara dieciocho relaciones con otras tablas de la base de datos PostgreSQL, de modo que su eliminación requiere la ejecución manual de dieciocho operaciones de borrado en cascada dentro de un hook del modelo, implementado mediante promesas anidadas que, si fallan, dejan el sistema en un estado de inconsistencia parcial.

Esta acumulación de deuda técnica durante seis años de modificaciones incrementales sin un proceso sistemático de mantenimiento ha generado un grado de acoplamiento que dificulta cualquier intervención por parte de colaboradores académicos temporales. El monolito no cuenta con un directorio de pruebas automatizadas, ni pipelines de integración continua, ni herramientas de análisis estático de código. El despliegue en producción se realiza de forma manual directamente sobre el servidor del Centro de Computación Gráfica de la Facultad de Ciencias, sin mecanismos que validen el comportamiento del sistema después de cada cambio. La autenticación emplea un mecanismo propietario basado en cadenas aleatorias almacenadas en una tabla `Session` de PostgreSQL, sin soporte para tokens JWT ni protocolos OAuth2, lo que impide la escalabilidad horizontal y complica la integración con estándares de seguridad modernos. El sistema no expone endpoints de métricas ni cuenta con agregación centralizada de logs; la única forma de detectar una anomalía es la observación directa de fallas visibles por parte de usuarios o mantenedores.

La respuesta ante un error del sistema es, por tanto, empírica y reactiva,

especialmente durante los semestres académicos en curso, cuando el pico de uso expone con mayor frecuencia las fallas acumuladas en la base de código. Este mecanismo de mantenimiento depende en gran medida de acciones manuales y del conocimiento implícito de los colaboradores, sin contar con mecanismos formales de monitoreo, observabilidad o diagnóstico que permitan gestionar el sistema de forma eficiente. Como consecuencia, se dificulta la detección temprana de problemas, se incrementan los tiempos de resolución de fallas y se limita la incorporación de nuevas características.

En este escenario se evidencia la necesidad de transformar tanto la arquitectura como el proceso de mantenimiento de PortalAsig. La migración hacia una arquitectura de microservicios resuelve el problema del acoplamiento arquitectónico, descomponiendo el sistema en dominios acotados con bases de datos independientes y ciclos de despliegue autónomos. No obstante, esta transformación introduce una complejidad operativa inherente a los sistemas distribuidos: múltiples procesos, múltiples bases de datos, latencia de red, tolerancia a fallos y monitoreo distribuido. En un entorno donde no existe un equipo de operaciones dedicado y donde el mantenimiento recae en colaboradores académicos temporales que permanecen uno o dos semestres, esta complejidad puede convertirse en un cuello de botella crítico si no se acompaña de mecanismos automatizados de validación, observabilidad y autogestión.

Frente a esta situación, se identifica la necesidad de un enfoque que combine la arquitectura modular con mecanismos de observabilidad distribuida y técnicas de inteligencia artificial, que permitan asistir el mantenimiento del sistema y reducir la carga cognitiva sobre el mantenedor humano. Este enfoque posibilita el paso de un esquema enteramente reactivo a uno sistemático, donde el propio ecosistema detecta anomalías, diagnostica causas y propone acciones de remediación que un operador evalúa y aprueba.

1.1. Justificación

La modernización del sistema PortalAsig responde a una realidad operativa concreta: el sistema carece de un equipo de desarrollo y operaciones de tiempo completo asignado. El único soporte técnico recurrente proviene del grupo docente, y las mejoras al sistema se originan exclusivamente en colaboradores académicos temporales —estudiantes de Trabajo Especial de Grado, de seminario o de servicio comunitario— que permanecen en el proyecto entre uno y dos semestres. Esta rotación perpetua implica que el conocimiento tácito acumulado sobre el código, la infraestructura y los procesos de despliegue se pierde cada vez que un colaborador concluye su período, obligando al siguiente a reconstruir ese conocimiento, al menos parcialmente, sobre una base de código de difícil comprensión.

El monolito de producción de PortalAsig se aloja en los servidores del Centro de Computación Gráfica de la Facultad de Ciencias, bajo una modalidad *on-premise* donde no existe acceso a servicios de computación en la nube ni equipo de DevOps dedicado. El despliegue se realiza de forma manual mediante conexión

directa al servidor. En estas condiciones, cualquier herramienta adicional que requiera infraestructura propia, configuración compleja o mantenimiento continuo constituye un pasivo técnico que el siguiente colaborador deberá asumir sin garantía de transferencia de conocimiento.

La adopción de una arquitectura basada en microservicios permite descomponer el sistema en dominios independientes, cada uno comprensible de forma aislada y con un área de impacto acotada ante modificaciones. Sin embargo, esta transformación incrementa la complejidad operativa: un ecosistema distribuido tiene múltiples puntos de fallo, cada servicio expone sus propias métricas y logs, y la correlación de problemas entre nodos requiere observar simultáneamente múltiples fuentes de datos. Sin operadores fijos que conozcan la arquitectura en profundidad, esta complejidad puede superar los beneficios arquitectónicos si no se acompaña de automatización.

En este contexto, la incorporación de un mecanismo de autogestión del mantenimiento asistido por inteligencia artificial representa una alternativa viable para automatizar tareas de análisis, detección de anomalías y apoyo a la toma de decisiones. Este enfoque permite reducir la dependencia de intervenciones manuales y mejorar la capacidad de respuesta ante fallas, siendo especialmente relevante en un sistema donde los recursos humanos son limitados, temporales y rotativos. El resultado no es un sistema que elimine al mantenedor, sino uno que reduce su carga cognitiva y acelere sus decisiones mediante diagnósticos consolidados y recomendaciones estructuradas.

1.2. Objetivo General

Implementar un modelo de mantenimiento asistido por inteligencia artificial para el sistema PortalAsig sobre una arquitectura de microservicios.

1.3. Objetivos Específicos

- Documentar el estado actual del sistema PortalAsig y caracterizar sus carencias estructurales mediante análisis de código fuente, modelo de datos y procesos de despliegue.
- Diseñar una arquitectura de microservicios que desacople el backend en dominios independientes (UAA, Site, Notify), cada uno con su propia base de datos, su esquema de versionado y su ciclo de despliegue autónomo.
- Adaptar el frontend heredado para operar como cliente de la nueva arquitectura distribuida, reestructurando el estado por dominio, migrando la autenticación a estándares OAuth2/JWT e implementando mecanismos de comunicación con los microservicios backend.
- Implementar técnicas sistemáticas de aseguramiento de calidad que abarquen análisis estático, pruebas de integración sobre bases de datos reales,

medición de cobertura de código, validación end-to-end de la interfaz y automatización del pipeline de integración continua.

- Diseñar e implementar el servicio PAIMA, que ejecute un ciclo MAPE-K donde las fases de Análisis y Planificación se deleguen a un modelo de inteligencia artificial, configurado con proveedores intercambiables y fallback determinista.
- Instrumentar mecanismos de observabilidad distribuida para la recolección de métricas, agregación de logs y visualización centralizada, que constituyan la base sensorial sobre la cual PAIMA opere.
- Evaluar el ecosistema resultante mediante pruebas de integración, validación end-to-end, simulación de caos con PAIMA y análisis comparativo cualitativo frente al monolito legacy.

Capítulo 2

Marco Teórico

2.1. Evolución de los Paradigmas Web

Los paradigmas de la Web han evolucionado desde modelos estáticos de solo lectura hasta arquitecturas distribuidas, autónomas e inteligentes. Esta transformación redefine los requisitos técnicos de los sistemas de software y establece el contexto conceptual para la migración arquitectónica abordada en este trabajo.

2.1.1. De la Web 1.0 a la Web 3.0

La World Wide Web ha atravesado transformaciones estructurales que definen no solo cómo se consume información, sino cómo se construyen y operan los sistemas de software. La Web 1.0, predominante durante la década de 1990, operaba bajo un modelo de lectura pasiva: páginas estáticas, contenido generado exclusivamente por administradores y una arquitectura cliente-servidor centralizada donde el servidor era el único nodo productor de información. El usuario era un consumidor sin capacidad de modificación.

La transición hacia la Web 2.0, consolidada a partir de 2004 [4], introdujo la participación activa del usuario. Plataformas sociales, wikis, blogs y sistemas de gestión de contenido transformaron la web en un espacio colaborativo donde los usuarios generan datos, establecen relaciones y modifican el estado de las aplicaciones en tiempo real. Sin embargo, esta evolución incrementó la complejidad de los sistemas backend: arquitecturas monolíticas que originalmente atendían flujos simples de lectura tuvieron que adaptarse para procesar escrituras concurrentes, relaciones sociales, notificaciones en tiempo real y volúmenes masivos de datos generados por los usuarios. La acumulación de funcionalidades sobre bases monolíticas originó, en muchos casos, sistemas de alta complejidad y baja mantenibilidad.

El término Web 3.0 fue acuñado originalmente por Berners-Lee, Hendler y Lassila para describir la Web Semántica, una visión donde los datos estarían estructurados de forma que las máquinas pudieran interpretarlos y razonar sobre

ellos de manera autónoma [5]. Durante los años siguientes, el ecosistema de las criptomonedas adoptó la expresión para referirse a una internet descentralizada basada en tecnologías de contabilidad distribuida (blockchain), asociándose con la descentralización económica y la propiedad de datos por parte de los usuarios [6]. Si bien esta acepción ha dominado el discurso popular e industrial durante la década de 2010, la literatura reciente ha reinterpretado el paradigma desde la perspectiva de la ingeniería de software. Shen et al. [7] proponen un framework arquitectónico para Web 3.0 donde la inteligencia artificial resuelve desafíos fundamentales en cada capa del ecosistema, mientras que Kuai et al. [8] introducen el concepto de Web Intelligence 3.0 como materialización de una sociedad inteligente interconectada. Este trabajo adopta esta última acepción, reconociendo la Web 3.0 como un paradigma de sistemas distribuidos, autónomos e inteligentes, donde la inteligencia artificial, los agentes autónomos y la arquitectura de microservicios constituyen su infraestructura técnica fundamental, más allá de las connotaciones exclusivamente financieras de la tecnología de contabilidad distribuida.

2.1.2. Web 3.0: Distribución, Autonomía e Inteligencia Artificial

La literatura reciente reinterpreta el paradigma de la Web 3.0 desde la perspectiva de la ingeniería de software como un espacio donde convergen tres tendencias tecnológicas, cada una con raíces en disciplinas distintas pero complementarias entre sí.

Distribución arquitectónica. Tanto la acepción blockchain de Web 3.0 [6] como la propuesta de Web Intelligence 3.0 [8] comparten el principio de que los sistemas deben dejar de depender de un único proceso monolítico para descomponerse en componentes independientes que operan sobre una red. Esta propiedad no implica necesariamente una red pública de blockchain, sino una red interna de servicios interconectados mediante protocolos estándar, típicamente HTTP/REST o mensajería asíncrona. La distribución habilita la evolución continua del software sin interrumpir la operación global y constituye la base material sobre la cual se construyen las demás capacidades.

Observabilidad y auto-gestión. La complejidad operativa inherente a los sistemas distribuidos exige mecanismos de monitoreo, agregación de telemetría y toma de decisiones automatizada. Esta necesidad, heredada de la computación autónoma (Sección 2.5), transforma el mantenimiento de software de un proceso reactivo y manual a un ciclo continuo donde el sistema monitorea su propio estado, detecta anomalías y propone acciones de corrección. La observabilidad no es un complemento optativo: es la condición previa que permite a los mecanismos de control razonar sobre el estado interno del ecosistema.

Inteligencia artificial como asistente operativo. La inteligencia artificial ha comenzado a desempeñar un papel transversal en la infraestructura de Web 3.0 [7], resolviendo desafíos que van desde la gestión de datos hasta la gobernanza del ecosistema. En particular, los modelos de lenguaje de gran escala (LLMs) pueden interpretar telemetría operativa, sintetizar diagnósticos en lenguaje

natural y proponer planes de remediación que un operador humano evalúa y aprueba. En esta acepción, la IA no sustituye al administrador: actúa como un asistente que reduce la carga cognitiva y acelera la toma de decisiones.

Es importante aclarar que estas tres tendencias no constituyen una definición normativa de Web 3.0, sino una convergencia observable en la literatura técnica reciente. Para que un sistema heredado pueda incorporar estas capacidades, su arquitectura subyacente debe permitir la distribución de componentes, la exposición de telemetría y la integración de módulos inteligentes. Un monolito acoplado, sin instrumentación ni puntos de extensión, constituye una barrera estructural que impide esta evolución.

2.2. Arquitecturas de Software

El diseño arquitectónico constituye la base sobre la cual se construye cualquier sistema de información. La elección entre un monolito y una descomposición en servicios independientes define las propiedades de escalabilidad, mantenibilidad y resiliencia del ecosistema.

2.2.1. Arquitecturas Monolíticas

El desarrollo de software tradicional frecuentemente se orienta hacia la construcción de aplicaciones monolíticas. En este tipo de arquitectura, todos los componentes del sistema —interfaz de usuario, lógica de negocio y acceso a datos— se empaquetan y despliegan como una única unidad lógica y ejecutable [9]. Si bien este enfoque simplifica el desarrollo inicial, las pruebas y el despliegue a pequeña escala, tiende a presentar problemas significativos de escalabilidad y mantenimiento a medida que la base de código crece.

Un fenómeno recurrente en sistemas monolíticos de larga vida es la *deuda técnica*: el conjunto de compromisos de diseño y codificación que aceleran la entrega en el corto plazo a costa de dificultar la evolución futura. La deuda técnica se manifiesta en controladores de dimensiones críticas, modelos de datos con acoplamiento referencial extremo, ausencia de pruebas automatizadas y dependencias globales que eliminan cualquier posibilidad de prueba unitaria aislada. Cuando la deuda acumulada supera un umbral crítico, el sistema se convierte en lo que se denomina *big ball of mud* [10]: una masa de código sin estructura discernible donde cualquier modificación introduce efectos colaterales impredecibles.

En un monolito, un fallo en cualquier componente puede comprometer la estabilidad de la aplicación completa. La actualización de una funcionalidad menor requiere el redesplicue del sistema entero, lo que incrementa el riesgo operativo y prolonga los tiempos de indisponibilidad. Además, la ausencia de límites arquitectónicos claros dificulta que nuevos colaboradores comprendan el sistema sin depender del conocimiento tácito de los mantenedores originales.

2.2.2. Arquitecturas Basadas en Microservicios

Para mitigar las deficiencias de los monolitos, la industria evolucionó hacia la arquitectura basada en microservicios. Fowler y Lewis [11] definen los microservicios como un enfoque de desarrollo en el que una aplicación única se construye como una suite de pequeños servicios, donde cada uno ejecuta su propio proceso y se comunica mediante mecanismos ligeros, usualmente APIs HTTP/REST. Estos servicios están contruidos alrededor de capacidades de negocio, son desplegables de manera independiente y pueden utilizar diferentes tecnologías de almacenamiento de datos.

El principio fundamental que sustenta los microservicios es el de *contextos acotados* (bounded contexts), definido por Evans en el *Domain-Driven Design* [12]. Cada servicio encapsula un modelo de datos y una lógica de negocio coherentes, minimizando las dependencias con los demás. Esta descomposición permite que un nuevo colaborador comprenda y modifique un dominio específico sin necesidad de reconstruir el modelo mental del sistema completo, reduciendo la carga cognitiva que impone una base de código monolítica sobre personal de mantenimiento rotativo.

No obstante, la adopción de microservicios introduce complejidad operativa inherente a los sistemas distribuidos: latencia de red, tolerancia a fallos, monitoreo distribuido, consistencia eventual de datos y orquestación de despliegues [9]. Esta complejidad no es un defecto del enfoque, sino una consecuencia directa del intercambio: se sacrifica simplicidad operativa unitaria a cambio de flexibilidad evolutiva y resiliencia. Sin los mecanismos adecuados de observabilidad y automatización, la complejidad operativa puede superar los beneficios arquitectónicos.

2.2.3. Comparación entre Arquitecturas Monolíticas y Microservicios

La principal diferencia radica en el acoplamiento y la unidad de despliegue. Las arquitecturas monolíticas ofrecen simplicidad operativa en etapas tempranas pero sufren de alto acoplamiento interno. Por el contrario, los microservicios brindan alta cohesión por dominio, escalabilidad independiente por servicio y resiliencia ante fallos aislados. Un servicio caído no compromete la totalidad del ecosistema, siempre que existan mecanismos de tolerancia a fallos en los consumidores.

En el contexto de sistemas académicos con equipos rotativos de mantenimiento, la elección arquitectónica tiene implicaciones prácticas directas. Un monolito obliga a cada nuevo colaborador a comprender la totalidad del sistema antes de poder realizar cualquier modificación, complicando el desarrollo de nuevas características. Un ecosistema de microservicios distribuye la complejidad pero exige que cada servicio sea comprensible de forma aislada y que existan mecanismos automatizados de validación que reduzcan la dependencia del conocimiento individual.

2.3. Tecnologías para el Desarrollo y Operación de Microservicios

La migración a microservicios requiere un ecosistema tecnológico que abarque desde la construcción del código hasta la observación del sistema en producción. A continuación se describen las herramientas y frameworks seleccionados para el desarrollo del presente trabajo, agrupados por función operativa.

2.3.1. Contenedores y Orquestación

La portabilidad y el aislamiento de los artefactos de software son condiciones necesarias para desplegar microservicios de forma reproducible, en particular en infraestructura *on-premise* donde no se dispone de servicios gestionados en la nube. Esta subsección presenta las tecnologías de contenedorización y orquestación evaluadas para empaquetar, distribuir y operar los servicios del ecosistema.

Docker [13] es una plataforma de contenedores que empaqueta una aplicación junto con todas sus dependencias —bibliotecas, configuraciones y variables de entorno— en una unidad portable e invariante denominada imagen. Un contenedor ejecuta una instancia de esta imagen de forma aislada sobre el kernel del sistema operativo host, sin requerir una máquina virtual completa. Esta característica reduce el consumo de recursos y garantiza que el comportamiento del software sea idéntico en los entornos de desarrollo, prueba y producción.

Docker Compose [14] es una herramienta de orquestación local que permite describir un ecosistema completo de contenedores —microservicios, bases de datos, proxies, herramientas de observabilidad— en un único archivo declarativo. Mediante un comando único se levanta toda la red de contenedores con sus dependencias, volúmenes y configuraciones de red interna. Frente a orquestadores más sofisticados como Kubernetes, Docker Compose ofrece simplicidad operativa para entornos sin requisitos de autoescalado o alta disponibilidad multi-nodo, lo cual resulta adecuado para el contexto de servidores universitarios *on-premise*.

2.3.2. Framework y Construcción

La selección del framework de backend determinó gran parte del ecosistema tecnológico del nuevo sistema. Se evaluaron dos alternativas principales.

Node.js con Express.js [15] es el stack del monolito legacy de PortalAsig. Express.js es un framework minimalista para Node.js que permite construir servidores HTTP con poco código boilerplate. Entre sus ventajas se encuentra la curva de aprendizaje reducida para desarrolladores con experiencia en JavaScript, la gran cantidad de paquetes disponibles en npm y el modelo de eventos no bloqueante que maneja eficientemente operaciones de entrada y salida. Sin embargo, el ecosistema Node.js carece de soporte nativo para observabilidad distribuida (Micrometer, Actuator), configuración centralizada (Config Client), seguridad OAuth2/JWT y ORM maduro, lo que obliga a depender de bibliotecas de terceros para funcionalidades críticas. Además, la tipificación débil de JavaScript

permite que errores de tipo pasen inadvertidos hasta la ejecución. La alternativa habitual —adoptar TypeScript— introduce una capa adicional de complejidad en la configuración del proyecto, la definición de tipos y la integración con bibliotecas de terceros, incrementando el conocimiento requerido para que un colaborador temporal contribuya de forma segura.

Spring Boot [16] es un framework de desarrollo para la plataforma Java que simplifica la creación de aplicaciones autónomas y de grado empresarial. Proporciona de forma inmediata soporte para seguridad (OAuth2 y JWT), observabilidad (Micrometer y Actuator), comunicación entre servicios (WebClient), configuración centralizada (Config Client) y persistencia (JPA). La tipificación fuerte de Java facilita la detección temprana de errores en tiempo de compilación, en contraste con lenguajes dinámicos donde las incompatibilidades de tipos pueden pasar inadvertidas hasta la ejecución. Se seleccionó Spring Boot porque la madurez de su ecosistema para arquitecturas de microservicios, la integración nativa con herramientas de observabilidad y testing, y la abundancia de documentación y desarrolladores disponibles lo convierten en la opción más robusta para un sistema enterprise mantenido por colaboradores académicos temporales.

Spring Cloud [17] es un conjunto de herramientas que extienden Spring Boot para escenarios distribuidos. Entre sus componentes destaca **Spring Cloud Config Server**, que centraliza la gestión de propiedades y secretos en un repositorio Git, permitiendo versionar los cambios de configuración junto al código fuente y simplificando la rotación de credenciales sin requerir redesplicue de los servicios.

Maven [18] es una herramienta de gestión de dependencias y construcción para proyectos Java. Organiza el código mediante un modelo de herencia de proyectos donde un POM padre centraliza las versiones de las dependencias y los plugins. Este mecanismo, denominado *Bill of Materials* (BOM), garantiza consistencia entre los distintos módulos del ecosistema y elimina conflictos de versiones. **Gradle** constituye una alternativa moderna que emplea una sintaxis declarativa basada en Kotlin o Groovy y ofrece tiempos de compilación inferiores gracias a su sistema de cache incremental; no obstante, la madurez del ecosistema de plugins para Spring Boot en Maven determinó su selección para este trabajo.

Lombok [19] es una biblioteca de anotaciones que reduce el código repetitivo en clases Java. Mediante anotaciones como `@Getter`, `@Setter`, `@Builder` y `@AllArgsConstructor`, Lombok genera automáticamente métodos de acceso, constructores y patrones de creación en tiempo de compilación, eliminando decenas de líneas de código boilerplate por entidad. Esta reducción mejora la legibilidad y disminuye el riesgo de inconsistencias cuando múltiples colaboradores modifican el mismo modelo de datos.

MapStruct [20] es un generador de código que automatiza el mapeo entre objetos de dominio (entidades JPA) y objetos de transferencia (DTOs). En lugar de escribir manualmente conversiones campo por campo, el desarrollador define una interfaz anotada y MapStruct genera la implementación en tiempo de compilación. Esta práctica garantiza que cada cambio en la estructura de una entidad se refleje inmediatamente en su DTO correspondiente, evitando errores

de sincronización entre capas. Como alternativa se evaluó **ModelMapper**, que ofrece configuración por convenciones sin necesidad de interfaces explícitas; sin embargo, MapStruct fue preferido por su menor overhead en tiempo de ejecución y su integración nativa con el ciclo de compilación de Maven.

2.3.3. Seguridad y Comunicación

En una arquitectura distribuida la seguridad ya no puede delegarse a un único punto de control: cada servicio expone endpoints que deben protegerse de forma individual y la comunicación entre componentes atraviesa la red en lugar de resolverse en memoria. Esta subsección define los mecanismos de autenticación, autorización y transporte que gobiernan el acceso al ecosistema.

JSON Web Token (JWT) es un estándar abierto (RFC 7519) [21] que define un formato compacto y autocontenido para transmitir información de autenticación entre partes. Un token JWT contiene tres segmentos codificados en Base64: un encabezado con el algoritmo de firma, un *payload* con las reclamaciones del usuario (identidad, roles, expiración) y una firma criptográfica que garantiza la integridad del mensaje. Los servicios pueden validar un JWT sin necesidad de consultar una base de datos de sesiones en cada petición, lo que habilita la escalabilidad horizontal.

OAuth2 [22] es un protocolo de autorización que permite a una aplicación obtener acceso limitado a los recursos de un usuario sin exponer sus credenciales. El flujo `client_credentials` permite que un microservicio se autentique directamente con sus propias credenciales para consumir APIs internas, mientras que el flujo de *password* autentica a usuarios finales. Ambos flujos emiten tokens de acceso con tiempo de expiración limitado que los servicios protegidos validan mediante la firma JWT compartida. Para evitar que el usuario deba iniciar sesión repetidamente, el protocolo define un *refresh token*: un token de mayor duración que el cliente puede intercambiar por un nuevo par de tokens de acceso cuando el original expire, manteniendo la sesión activa sin requerir credenciales nuevamente.

Nginx [23] es un servidor web de alto rendimiento que en este contexto opera como *proxy inverso*: recibe las peticiones del navegador, las enruta hacia el microservicio correspondiente y devuelve la respuesta al cliente. Esta capa intermedia permite servir el frontend estático, distribuir la carga entre réplicas y centralizar la terminación SSL.

Cross-Origin Resource Sharing (CORS) es un mecanismo de seguridad que controla qué dominios externos pueden realizar peticiones HTTP a un servicio. En una arquitectura de microservicios donde el frontend Vue.js se sirve desde un dominio distinto al de los servicios backend, CORS debe configurarse explícitamente en cada microservicio para permitir el intercambio de recursos entre orígenes autorizados.

Cookies y *localStorage* son mecanismos de almacenamiento del lado del cliente. Las cookies permiten que el navegador almacene pares clave-valor asociados a un dominio, con soporte nativo para expiración y atributos de seguridad (`HttpOnly`, `Secure`). *localStorage* ofrece un almacenamiento persistente de

mayor capacidad, accesible únicamente mediante JavaScript, pero carece de los mecanismos de expiración y protección contra ataques XSS (cross-site scripting) que proporcionan las cookies. En el contexto de autenticación, las cookies resultan preferibles para almacenar tokens de sesión porque el navegador las envía automáticamente en cada petición y las elimina al expirar, reduciendo la superficie de ataque frente a vulnerabilidades de inyección de scripts.

Apache Kafka [24] es una plataforma de mensajería asíncrona basada en el patrón publicación-suscripción. Los servicios productores emiten eventos hacia *tópicos* gestionados por un *broker* central, y los servicios consumidores los procesan de forma desacoplada, sin que emisor y receptor deban estar disponibles simultáneamente. Este mecanismo resulta adecuado para operaciones que no requieren una respuesta inmediata —como el despacho de correos electrónicos—, ya que evita que una falla o una lentitud en el servicio consumidor se propague al flujo síncrono del servicio productor.

2.3.4. Persistencia

Bajo el patrón *database per service* cada microservicio es dueño exclusivo de su esquema de datos, lo que exige definir con precisión los motores relacionales, las herramientas de mapeo objeto-relacional y los mecanismos de versionamiento que garantizan la integridad y evolución de la información. A continuación se describen las tecnologías de persistencia seleccionadas.

Java Persistence API (JPA) [25] es una especificación de Java para el mapeo objeto-relacional (ORM). Permite definir las entidades del modelo de datos como clases Java anotadas y delegar la generación de consultas SQL al framework. **Hibernate** [26] es la implementación de referencia de JPA en el ecosistema Spring Boot. Esta combinación abstrae las diferencias de dialecto entre motores de base de datos y reduce la cantidad de código SQL explícito que el desarrollador debe escribir.

Flyway [27] es una herramienta de migración de bases de datos que aplica scripts SQL versionados durante el arranque de cada servicio. Los scripts se organizan en el directorio `db/migration/` con un prefijo de versión obligatorio (`V1_`, `V2_`), lo que garantiza la coherencia entre el esquema de la base de datos y la versión del código desplegado. Este enfoque elimina las migraciones manuales y permite reproducir el estado de la base de datos en cualquier entorno a partir del repositorio de código fuente.

MySQL [28] es un motor de base de datos relacional maduro, con integración nativa en Spring Boot a través del conector oficial `mysql-connector-j`, herramientas de administración accesibles y documentación extensa. En una arquitectura de microservicios se adopta el principio de una instancia aislada por servicio, eliminando el acoplamiento referencial del modelo monolítico y permitiendo que cada dominio evolucione su esquema de forma independiente.

PostgreSQL [29] es un motor de base de datos relacional con soporte avanzado para tipos de datos complejos, consultas anidadas y extensibilidad. En el contexto de PortalAsig, PostgreSQL fue el motor utilizado por el backend monolítico original, que centralizaba todas las entidades del sistema en un único

schema sin aislamiento por dominio. La selección de MySQL para el nuevo ecosistema responde a criterios operativos: su instalación y administración en entornos locales resultan más simples para colaboradores académicos temporales, sus herramientas de gestión son ampliamente conocidas y su integración con Spring Boot es inmediata mediante el conector oficial. Este criterio se desarrolla con mayor detalle en el Capítulo 3.

2.3.5. Observabilidad Distribuida

La observabilidad de un sistema distribuido se fundamenta en tres pilares de telemetría: métricas, logs y trazabilidad. Sridharan [30] distingue entre *monitoreo* —el acto de observar el estado general y predecible de un sistema— y *observabilidad* —la cualidad que permite inferir estados internos basándose únicamente en el conocimiento de sus salidas externas—.

Spring Boot Actuator expone endpoints de administración y diagnóstico sobre cada microservicio, incluyendo `/actuator/health` para verificar el estado de salud y `/actuator/prometheus` para exportar métricas en formato compatible con Prometheus. **Micrometer** es la fachada de instrumentación que Actuator utiliza internamente para recolectar métricas de JVM, uso de memoria, tiempos de respuesta y contadores de peticiones HTTP.

Prometheus [31] es un sistema de monitoreo y alerta que recolecta métricas mediante un modelo de extracción periódica (*scraping*) sobre los endpoints expuestos por los microservicios. Almacena las series temporales en una base de datos propia y permite consultarlas mediante un lenguaje de expresiones (PromQL).

Loki es un sistema de agregación de logs diseñado específicamente para entornos distribuidos. A diferencia de soluciones como Elasticsearch, que indexan el contenido completo de cada registro, Loki indexa únicamente las etiquetas (*labels*) asociadas a los logs, logrando un consumo de recursos menor. Los microservicios envían sus registros a Loki mediante un *appender* configurado en el framework de logging.

Grafana [32] es una plataforma de visualización que unifica métricas de Prometheus y logs de Loki en dashboards interactivos. Permite correlacionar anomalías numéricas —como un pico de latencia— con el contexto textual de los logs en un único punto de consulta, acelerando el diagnóstico de incidentes.

2.3.6. Calidad de Software y Testing

La migración a microservicios no garantiza por sí sola la mantenibilidad del sistema. Es necesario incorporar prácticas sistemáticas de aseguramiento de calidad que detecten problemas antes de que lleguen a producción.

Checkstyle [33] es una herramienta de análisis estático de código que verifica el cumplimiento de una guía de estilo definida en un archivo de configuración XML. Se integra en la fase de compilación de Maven de forma que cualquier violación —longitud de línea excedida, convenciones de nombres incorrectas, ausencia de Javadoc— interrumpe el *build*. **SpotBugs** es otra herramienta de

análisis estático, orientada a la detección de patrones de bug conocidos (null pointers, fugas de recursos, comparaciones incorrectas) en el bytecode Java. Si bien SpotBugs aporta valor en la detección de defectos de lógica, se seleccionó Checkstyle porque la prioridad del proyecto fue garantizar la legibilidad y uniformidad del código fuente —aspectos críticos cuando múltiples colaboradores rotativos modifican la misma base de código—, mientras que la detección de defectos de lógica se cubre mediante las pruebas de integración sobre bases de datos reales.

JaCoCo [34] es un plugin de cobertura de código para Java que instrumenta el *bytecode* durante la ejecución de las pruebas y genera un reporte detallado del porcentaje de líneas y ramas ejecutadas. El reporte se integra con el pipeline de integración continua para bloquear la fusión de código que descienda por debajo del umbral establecido.

Testcontainers [35] es una biblioteca que levanta contenedores Docker efímeros durante la fase de pruebas de Maven. Permite ejecutar tests de integración sobre instancias reales de MySQL, aplicar las migraciones Flyway correspondientes y destruir el contenedor al finalizar. Este enfoque garantiza que las pruebas validen comportamientos que dependen del dialecto SQL real, como restricciones de clave foránea y transacciones concurrentes, en contraste con bases de datos en memoria como H2.

Se evaluaron tres alternativas para la automatización de pruebas end-to-end.

Selenium WebDriver [36] constituye el estándar más consolidado de la industria. Opera mediante un protocolo de comunicación entre un driver específico del navegador y el código de prueba, lo que permite ejecutar tests en múltiples navegadores y plataformas. Sin embargo, esta arquitectura de intermediación introduce latencia adicional y condiciones de sincronización entre el driver y el navegador que, en sistemas de interfaz compleja, producen inestabilidad en las pruebas.

Playwright [37] es una herramienta más reciente que soporta múltiples navegadores (Chromium, WebKit, Firefox) mediante una arquitectura de eventos que permite ejecución paralela rápida. Su API es robusta y su soporte multi-navegador supera al de Cypress. No obstante, su ecosistema es relativamente nuevo y su curva de aprendizaje es ligeramente mayor para equipos sin experiencia previa en automatización de interfaz.

ESLint [38] es un analizador estático de código JavaScript que detecta patrones problemáticos, violaciones de convenciones de estilo y potenciales errores de lógica antes de la ejecución. Se integra en el ciclo de desarrollo del frontend mediante un script de `npm` que verifica el código antes de compilar la aplicación, garantizando que solo código que cumple con el estándar definido llegue al repositorio.

Prettier [39] es un formateador de código que aplica un estilo consistente a través del proyecto. A diferencia de ESLint, que detecta problemas semánticos, Prettier se encarga exclusivamente de la presentación: indentación, saltos de línea, comillas y espaciado. La combinación de ESLint y Prettier establece un estándar de calidad reproducible para el código JavaScript del frontend, reduciendo las discrepancias de estilo entre colaboradores y eliminando debates sobre formato

en las revisiones de código.

Cypress [40] se ejecuta dentro del mismo *runtime* del navegador, eliminando por completo la capa de intermediación del WebDriver. Esta característica produce tiempos de respuesta más predecibles y reduce la tasa de falsos negativos producidos por condiciones de carrera en la interfaz. Además, Cypress incluye mecanismos de espera automática integrados que eliminan la necesidad de declarar tiempos de espera explícitos en el código de prueba. Se seleccionó Cypress porque el balance entre velocidad, estabilidad y facilidad de uso resulta óptimo para un proyecto académico donde el tiempo de desarrollo de pruebas es un recurso limitado y donde el ecosistema Vue.js cuenta con integración nativa con esta herramienta.

Para la integración continua se evaluaron dos alternativas.

Jenkins [41] es una plataforma de integración continua autoalojada que ofrece una amplia gama de plugins y un alto grado de configurabilidad. Su principal ventaja es la capacidad de adaptarse a flujos de trabajo complejos y entornos empresariales. Sin embargo, requiere un servidor propio, configuración manual de plugins, actualizaciones periódicas y mantenimiento de la infraestructura. En un contexto sin personal de operaciones dedicado, esta complejidad operativa representa un pasivo técnico que el siguiente colaborador deberá asumir.

GitHub Actions [42] es un servicio de integración continua integrado en GitHub que ejecuta pipelines definidos mediante archivos YAML en el mismo repositorio del código. El flujo de trabajo se dispara automáticamente en cada *pull request* y en cada cambio sobre la rama principal, realizando en secuencia: compilación, análisis de estilo, ejecución de pruebas y generación del reporte de cobertura. Se seleccionó GitHub Actions sobre Jenkins porque la ejecución corre sobre los servidores de GitHub sin costo adicional para repositorios públicos, eliminando la necesidad de infraestructura propia y reduciendo la carga operativa sobre el equipo de mantenimiento. Las ramas principales de cada repositorio se protegen mediante reglas de *branch protection* que exigen el paso exitoso de la pipeline antes de permitir la fusión del código.

k6 [43] es una herramienta de código abierto para pruebas de carga que permite simular tráfico concurrente sobre APIs HTTP mediante scripts escritos en JavaScript. A diferencia de herramientas de pruebas funcionales que verifican la corrección del comportamiento, k6 mide el rendimiento del sistema bajo condiciones de estrés: latencia percentil, throughput y tasa de errores ante un número creciente de usuarios virtuales. Se seleccionó **k6** como herramienta de generación de carga para el plan de benchmarking documentado en el Capítulo 4, diseñado para comparar el comportamiento del monolito legacy y el ecosistema de microservicios bajo cargas sintéticas equivalentes.

2.3.7. Documentación y Frontend

La documentación viva de las APIs y la capa de presentación constituyen los dos puntos de contacto del ecosistema con sus consumidores, programáticos y humanos. Esta subsección describe los estándares y frameworks empleados para especificar los contratos REST y para construir la interfaz de usuario del portal.

OpenAPI [44] es una especificación estándar para describir APIs REST de forma declarativa. **SpringDoc OpenAPI** es una biblioteca que genera automáticamente una interfaz interactiva de documentación (Swagger UI) a partir de las anotaciones presentes en los controladores REST. Esta documentación viva se actualiza con cada cambio en el código, eliminando la necesidad de mantener manuales de API separados.

Vue.js [45] es un framework progresivo para la construcción de interfaces de usuario. A diferencia de frameworks monolíticos, Vue permite adoptar sus características de forma incremental: un desarrollador puede integrar un componente Vue en una página HTML existente o construir una aplicación de página única (SPA) completa. Su modelo de reactividad y su ecosistema de herramientas (Vuex para gestión de estado, Vue Router para navegación) facilitan la construcción de interfaces tolerantes a fallos que absorben errores de red sin bloquear la experiencia del usuario.

Axios [46] es un cliente HTTP basado en promesas para JavaScript. En el frontend de PortalAsig, Axios gestiona la comunicación entre la interfaz de usuario y los microservicios backend, permitiendo configurar instancias independientes con URL base, tiempos de espera y cabeceras personalizadas por servicio. Esta capacidad resulta esencial en una arquitectura distribuida donde el frontend debe comunicarse con múltiples endpoints (UAA, Site, PAIMA) sin depender de un único punto de entrada.

Bootstrap-Vue [47] es una biblioteca de componentes de interfaz de usuario que integra el framework CSS Bootstrap con Vue.js. Proporciona componentes accesibles y responsivos (tablas, formularios, modales, navegación) que aceleran el desarrollo del frontend sin requerir la escritura manual de estilos CSS complejos. Su adopción garantiza consistencia visual en toda la aplicación y reduce el tiempo necesario para implementar nuevas vistas.

2.3.8. Modelos de Lenguaje de Gran Escala y Locales

Los **modelos de lenguaje de gran escala** (LLMs, por sus siglas en inglés) son redes neuronales entrenadas sobre vastos corpus de texto que pueden generar, resumir, traducir y razonar sobre lenguaje natural. En el contexto de operaciones de infraestructura, los LLMs actúan como asistentes que interpretan telemetría operativa —métricas, logs, topología de servicios— y sintetizan diagnósticos legibles por humanos. Reciben instrucciones de texto denominadas *prompts*, que estructuran el contexto técnico en un formato que el modelo puede procesar.

Los proveedores de modelos de lenguaje pueden clasificarse en dos categorías según su modalidad de ejecución.

APIs remotas comerciales. Servicios como OpenAI (GPT-4, GPT-3.5), Google (Gemini) o Moonshot AI (Kimi) ofrecen acceso a modelos de gran capacidad mediante interfaces de programación en la nube. Estos modelos han sido entrenados sobre vastos corpus de texto y exhiben un alto rendimiento en tareas de razonamiento, síntesis y generación de código. Su principal ventaja es la calidad de respuesta sin requerir infraestructura local de procesamiento. Su principal desventaja es la dependencia de conectividad externa, los costos por

token consumido y la transmisión de datos operativos potencialmente sensibles a servidores de terceros.

Modelos locales. Ollama [48] es una plataforma de código abierto que permite ejecutar modelos de lenguaje de forma local sobre hardware convencional, sin depender de APIs de terceros. Modelos como Llama, Gemma u otros pueden ejecutarse en estaciones de trabajo locales con recursos limitados, garantizando soberanía tecnológica y eliminando costos por uso de APIs remotas. Esta capacidad resulta especialmente relevante en entornos institucionales donde la conectividad externa es limitada o donde los datos operativos no pueden transmitirse a servicios en la nube por razones de seguridad. La contraparte es que los modelos locales suelen tener menor capacidad de razonamiento que sus equivalentes comerciales de mayor escala, y su ejecución continua exige recursos computacionales adicionales —memoria RAM, ciclos de CPU o aceleración GPU— que deben mantenerse dedicados al servicio del modelo, incrementando el consumo energético y el costo de infraestructura respecto a una invocación esporádica a una API remota.

En el contexto de este trabajo, se adoptó una arquitectura de proveedores configurables que permite alternar entre APIs remotas (para máxima calidad de diagnóstico) y modelos locales (para soberanía tecnológica), seleccionable mediante el Config Server sin modificación del código.

2.4. Mantenimiento de Software

Tras el despliegue inicial, un sistema de software requiere intervención continua para conservar su utilidad operativa. Las actividades de mantenimiento incluyen corrección de defectos detectados en producción, adaptación a cambios en el entorno tecnológico, mejora de rendimiento y prevención de fallos latentes.

2.4.1. Tipos de Mantenimiento

El estándar internacional ISO/IEC/IEEE 14764 [49] establece que el mantenimiento del software ocurre una vez que el sistema ha sido puesto en producción y lo categoriza en cuatro vertientes:

- **Correctivo:** Modificaciones reactivas para corregir fallos o *bugs* descubiertos durante la operación.
- **Adaptativo:** Modificaciones para asegurar que el software siga siendo funcional en un entorno tecnológico cambiante (migraciones de base de datos, actualizaciones de sistema operativo, cambios en dependencias).
- **Perfectivo:** Mejoras en el rendimiento o implementación de nuevas funcionalidades operativas sin alterar la lógica de negocio subyacente.
- **Preventivo:** Refactorización o mitigación técnica para prevenir fallos latentes o corregir la deuda técnica antes de que cause incidencias.

2.4.2. Retos en Sistemas Distribuidos

Realizar tareas de mantenimiento en arquitecturas basadas en microservicios introduce retos significativos. La falla no suele concentrarse en una sola línea de código, sino que puede deberse a interrupciones de red, fallos en contenedores terceros o latencias asíncronas [9]. Identificar la raíz del problema (Root Cause Analysis, RCA) consume una porción abrumadora del tiempo del desarrollador, lo cual incrementa el MTTR (Mean Time to Recovery).

En un ecosistema distribuido, la observabilidad no es un lujo sino un requisito operativo. Sin métricas por servicio, sin agregación centralizada de logs y sin trazabilidad distribuida, el diagnóstico se convierte en un proceso de ensayo y error que depende del conocimiento tácito del mantenedor. Esta dependencia es precisamente lo que la transición hacia la Web 3.0 busca eliminar, reemplazando el mantenimiento reactivo por ciclos de auto-gestión asistidos.

2.4.3. Prácticas Modernas de Aseguramiento de Calidad

Las técnicas de mantenimiento moderno trascienden la corrección de errores para abarcar la prevención sistemática de defectos y la reducción de la deuda técnica. La **integración continua** (CI) automatiza la compilación, el análisis estático y la ejecución de pruebas cada vez que un desarrollador propone un cambio, impidiendo que código que no cumple con los criterios de calidad llegue a la línea base del proyecto. En el contexto de este trabajo, el alcance de la integración continua se limita a la fase de validación automatizada; el despliegue continuo en entornos de preproducción o producción, conocido como entrega continua (CD), queda fuera del alcance dado que la infraestructura de despliegue automático requiere una arquitectura de orquestación que el presente trabajo no implementa.

El **análisis de cobertura de código** mide el porcentaje de líneas y ramas condicionales ejecutadas por la suite de pruebas. Un umbral mínimo de cobertura, validado automáticamente en cada *pull request*, impide que código no probado llegue a la línea base del proyecto. Las reglas de **protección de ramas** bloquean el envío directo de código a la rama principal, exigiendo que todo cambio pase por revisión humana y validación automatizada antes de su fusión.

Estas prácticas, en conjunto, transforman el mantenimiento de un proceso artesanal y dependiente del conocimiento tácito en un proceso sistemático, medible y reproducible. Constituyen la base sobre la cual un sistema puede evolucionar hacia la autonomía operativa, ya que la auto-adaptación requiere que el código alterado mantenga su validez estructural.

2.4.4. Ingeniería del Caos

La ingeniería del caos es la disciplina que valida la resiliencia de un sistema mediante la inyección controlada de fallos en un entorno de experimentación [50]. En lugar de esperar a que las fallas se manifiesten en producción, se provocan de forma deliberada —detener un servicio, saturar la red, agotar recursos—

para verificar empíricamente que el sistema se comporta como se espera ante condiciones adversas. La metodología establece un protocolo formal: definir un estado estable medible, formular una hipótesis sobre el comportamiento del sistema ante el fallo, introducir el fallo con un radio de impacto controlado y, finalmente, verificar o refutar la hipótesis mediante la observación de las métricas. En ecosistemas distribuidos, donde los puntos de fallo se multiplican, esta disciplina constituye el mecanismo de validación por excelencia de las propiedades de aislamiento y recuperación, y es la metodología que este trabajo aplica en el Capítulo 4 para validar la resiliencia del ecosistema y del ciclo de autogestión.

2.5. Computación Autonómica

Frente a la creciente complejidad operativa de los ecosistemas distribuidos, la computación autonómica busca transferir la gestión rutinaria de la infraestructura al propio sistema, limitando la intervención humana a la definición de políticas de gobierno.

2.5.1. Concepto y Propiedades Self-CHOP

Inspirada en el funcionamiento del sistema nervioso autónomo del cuerpo humano, la Computación Autonómica fue propuesta por IBM en 2001 para lidiar con la creciente complejidad de la gestión de sistemas informáticos [51]. El concepto define sistemas informáticos capaces de autogestionarse en base a políticas de alto nivel establecidas por administradores humanos, ocultando la complejidad subyacente de las operaciones técnicas.

Un sistema autonómico se rige por cuatro propiedades fundamentales, conocidas como Self-CHOP [52]:

- **Auto-configuración (Self-configuration):** Capacidad de instalar y adaptar componentes de software automáticamente sin intervención externa.
- **Auto-recuperación (Self-healing):** Habilidad para detectar, diagnosticar y reparar problemas operativos, interrupciones y fallos en el software o hardware.
- **Auto-optimización (Self-optimization):** Monitorización proactiva y ajuste continuo de los recursos para garantizar un rendimiento óptimo.
- **Auto-protección (Self-protection):** Capacidad de anticipar, detectar e identificar ataques maliciosos o fallos en cascada, tomando acciones para salvaguardar el sistema.

2.6. Modelo MAPE-K

Para operacionalizar la computación autónoma, IBM propuso un ciclo de control organizado en cinco elementos: monitoreo del entorno, análisis del estado actual, planificación de acciones, ejecución sobre el sistema y una base de conocimiento que alimenta cada fase.

2.6.1. Componentes del Ciclo

El modelo MAPE-K (Monitor, Analyze, Plan, Execute, Knowledge) es el marco arquitectónico de referencia introducido por IBM en 2003 para construir sistemas autónomos [51]. Divide el proceso de auto-gestión en cuatro fases apoyadas sobre una base de conocimiento compartida:

- **Monitor (Monitoreo):** Recopila información de topología, métricas y logs de los recursos gestionados.
- **Analyze (Análisis):** Procesa la información para entender el estado actual del sistema y determinar si se ha producido una anomalía.
- **Plan (Planificación):** Estructura las acciones necesarias para alcanzar los objetivos o solucionar la falla detectada.
- **Execute (Ejecución):** Aplica el plan a través de actuadores o comandos sobre el sistema objetivo.
- **Knowledge (Conocimiento):** Base de datos o repositorio histórico que nutre y es nutrido por las otras cuatro fases [53].

2.6.2. De MAPE-K a la Integración de Inteligencia Artificial

La implementación estricta de un único ciclo MAPE-K mediante reglas estáticas resulta efectiva en entornos controlados con patrones de fallo predecibles. Sin embargo, la transición hacia microservicios introdujo nuevos niveles de complejidad: múltiples puntos de fallo independientes, interacciones no lineales entre servicios y volúmenes de telemetría que superan la capacidad de análisis manual.

En este contexto, la literatura reciente ha propuesto enfoques híbridos donde la inteligencia artificial asume la función de razonador en las fases de Análisis y Planificación del ciclo MAPE-K. Esposito et al. [3] proponen un framework que integra MAPE-K con *agentic AI* para la detección y remediación autónoma de anomalías en sistemas de microservicios. Su trabajo demuestra que la combinación del ciclo MAPE-K con capacidades de inteligencia artificial generativa permite mantener la robustez y seguridad de ecosistemas distribuidos, reduciendo el tiempo de inactividad y monitoreando atributos de calidad como rendimiento, resiliencia y gestión de anomalías. En este enfoque, las fases de Análisis y Planificación se delegan a un modelo de lenguaje que interpreta el contexto

completo de un incidente —métricas, logs, topología de servicios— y propone un plan de acción adaptado, en lugar de depender de umbrales fijos configurados por un operador humano.

Sanwou, Quinton y Temple [54] extienden esta dirección hacia arquitecturas completamente distribuidas con su marco AWARE (*Assess, Weigh, Act, Reflect, Enrich*), que emplea agentes de IA autónomos capaces de colaboración entre nodos y aprendizaje continuo. Si bien AWARE representa una evolución prometedora, su implementación requiere una infraestructura multi-agente que excede los recursos disponibles en el contexto de este trabajo.

El servicio PAIMA (Sección 3.3) se configura como una **implementación práctica del framework propuesto por Esposito et al. [3]**, que integra el ciclo MAPE-K con capacidades de inteligencia artificial generativa para la detección y remediación autónoma de anomalías en microservicios. A diferencia del modelo original, donde las fases de Análisis y Planificación operan mediante reglas estáticas configuradas por un operador humano, el framework de Esposito delega estas fases a un modelo de lenguaje de gran escala que interpreta telemetría operativa y propone planes de acción adaptados. Esta decisión de diseño prioriza la operabilidad en un entorno sin equipo de operaciones dedicado: un servicio centralizado es más simple de desplegar, depurar y mantener que una red distribuida de agentes autónomos, al tiempo que incorpora la capacidad de razonamiento inteligente que caracteriza a la evolución del MAPE-K hacia la inteligencia artificial.

La fase Knowledge adquiere un rol central en esta implementación, ya que el historial de incidentes resueltos y las decisiones humanas aprobadas constituyen material de retroalimentación que permite refinar los *prompts* enviados al modelo de IA y mejorar progresivamente la calidad de los diagnósticos.

2.7. Sistemas Auto-adaptativos

Un sistema auto-adaptativo tiene la capacidad de modificar su comportamiento y estructura en tiempo de ejecución en respuesta a cambios en su entorno u operaciones. Weyns [55] establece que un sistema auto-adaptativo se construye alrededor de bucles de retroalimentación explícitos —típicamente estructurados mediante el modelo MAPE-K— que monitorean el sistema y su entorno, analizan el estado observado y ejecutan las adaptaciones necesarias, reduciendo la intervención humana directa en la operación.

Mientras que la computación autonómica abarca la visión completa de sistemas auto-manejables, la auto-adaptación es el mecanismo de ingeniería de software práctico para implementarla. La auto-adaptación requiere que el código alterado mantenga su validez estructural, lo cual hace que las prácticas de aseguramiento de calidad —cobertura de pruebas, análisis estático, integración continua— sean condiciones previas indispensables para cualquier forma de autonomía operativa.

2.8. Inteligencia Artificial aplicada al Mantenimiento de Software

El uso de algoritmos de aprendizaje automático e inteligencia artificial permite establecer líneas base del comportamiento normal de un sistema: tasa de errores habitual, latencia esperada, picos estacionales de tráfico. Cuando los patrones reales se desvían de estas líneas base predictivas, la IA puede alertar al equipo antes de que ocurra una interrupción total del servicio [56].

El advenimiento de los modelos de lenguaje de gran escala ha revolucionado la gestión de operaciones de IT. Al abstraer métricas matemáticas, archivos de log crudos y topología de servicios en representaciones de texto, los LLMs son capaces de sintetizar errores complejos en diagnósticos legibles por humanos. Actúan como asistentes para los ingenieros de operaciones, sugiriendo configuraciones óptimas para recuperar o escalar la infraestructura.

2.9. AIOps y Automatización de Operaciones

El término AIOps (Artificial Intelligence for IT Operations) fue acuñado por Gartner en 2016 [57] para describir la aplicación de Big Data, aprendizaje automático y otras tecnologías avanzadas a los flujos de operaciones de IT. AIOps mejora el monitoreo tradicional al correlacionar eventos ruidosos, encontrar la causa raíz con mayor velocidad y proporcionar remediación predictiva.

En ecosistemas orquestados por contenedores, AIOps puede predecir cuándo un servicio fallará analizando un aumento anormal de la memoria o la latencia. La integración de AIOps en modelos autónomos como MAPE-K representa el estado del arte en ingeniería de resiliencia, permitiendo que los sistemas no solo reaccionen ante fallos, sino que anticipen condiciones de riesgo antes de que se materialicen en interrupciones.

2.10. Integración de IA en Arquitecturas de Microservicios

La principal barrera para incorporar inteligencia artificial en operaciones es la fragmentación de los datos. En un entorno de microservicios, los registros están distribuidos en múltiples nodos. Para que un modelo de lenguaje o un modelo estadístico funcione, se requiere la implementación de patrones de agregación mediante herramientas como Loki y Prometheus, garantizando un punto de entrada centralizado de contexto [58].

Al abstraer las métricas y los logs como contexto para modelos generativos, los administradores obtienen diagnósticos en lenguaje natural. Esto democratiza la administración de servidores complejos y acelera drásticamente los tiempos de recuperación. Permite establecer un canal de auto-mantenimiento donde el sistema puede inferir su propio nivel de riesgo, recomendando a los equipos

humanos ajustar configuraciones antes de que una anomalía se convierta en una caída masiva.

En el contexto de la Web 3.0, esta integración no es una funcionalidad adicional sino una capacidad arquitectónica fundamental. Un sistema distribuido que no puede observarse a sí mismo, que no puede agregar sus propios registros y que no puede delegar el análisis a un modelo inteligente, permanece anclado en el paradigma de la Web 2.0: interactivo, pero no adaptativo. La transición hacia la autonomía requiere, como condición necesaria, una arquitectura que haga posible la observabilidad distribuida y la asistencia inteligente.

Capítulo 3

Marco Aplicativo

La arquitectura monolítica de PortalAsig acumula seis años de modificaciones incrementales sin un proceso sistemático de mantenimiento, generando un grado de acoplamiento que dificulta cualquier intervención por parte de colaboradores académicos temporales. Para superar esta situación, se diseñó e implementó un nuevo backend basado en microservicios que descompone el sistema en dominios independientes, cada uno con su propia base de datos, su ciclo de despliegue autónomo y mecanismos de validación automatizada que reducen la dependencia del conocimiento tácito. Sobre este ecosistema distribuido se construyó el servicio PAIMA, que asume la función de operador autónomo mediante un ciclo de control MAPE-K asistido por inteligencia artificial, monitoreando métricas y logs, diagnosticando anomalías y proponiendo acciones de remediación que mitigan la carga cognitiva sobre el mantenedor humano. Paralelamente, el frontend heredado fue adaptado para operar como cliente de la arquitectura distribuida, reestructurando el estado por dominio, migrando la autenticación a OAuth2/JWT y configurando múltiples instancias de comunicación con los microservicios backend.

3.1. Migración del Backend a una Arquitectura de Microservicios

La migración del backend constituye el eje estructural del presente trabajo. A continuación se describe el diagnóstico del sistema monolítico heredado, el diseño de la nueva arquitectura distribuida, el stack tecnológico seleccionado, las prácticas de aseguramiento de calidad incorporadas, la estrategia de despliegue y la comparación cualitativa entre ambos enfoques.

3.1.1. Análisis del Sistema Monolítico Legacy

El backend de PortalAsig en producción se ejecuta sobre la plataforma Node.js, empleando el framework Express.js como servidor de aplicaciones, el

ORM Bookshelf.js sobre el constructor de consultas Knex.js, y una base de datos PostgreSQL como único almacén de datos. Desde su puesta en operación en el año 2016, esta arquitectura monolítica atiende todas las funcionalidades del sistema —autenticación de usuarios, gestión de asignaturas, creación de sitios académicos, administración de evaluaciones, foros, entregas de archivos, envío de correos y encuestas— dentro de un único proceso desplegable.

Aunque este enfoque simplificó el desarrollo inicial y la puesta en marcha, la evolución del sistema durante múltiples semestres académicos sin un proceso sistemático de mantenimiento ha generado un acoplamiento progresivo que afecta la capacidad de modificación del software. En particular, se identifican las siguientes deficiencias estructurales que justifican la migración a una arquitectura modular.

Acoplamiento total en un único proceso. Todas las responsabilidades del backend se ejecutan dentro de un solo proceso Node.js, lo que implica que un fallo en cualquier módulo —por ejemplo, el procesamiento de archivos adjuntos— puede comprometer la estabilidad de toda la aplicación. No existe mecanismo de aislamiento que permita que un dominio de negocio falle sin afectar a los demás.

Controladores de dimensiones críticas. El archivo `site.js`, ubicado en el directorio `api/controllers/`, concentra la lógica de operaciones de sitios académicos, objetivos, bibliografías, contenidos temáticos, grupo docente, estudiantes, horarios, evaluaciones, calificaciones, foros, comentarios, entregas, archivos, vídeos, enlaces, planificaciones, noticias y encuestas. Este controlador alcanza un total de 3.629 líneas de código, convirtiéndolo en un componente de difícil comprensión y alto riesgo de introducir efectos colaterales ante cualquier modificación.

Modelo de datos con acoplamiento referencial extremo. La entidad `Site`, definida en el archivo `api/models/site.js`, declara explícitamente dieciocho relaciones con otras entidades del sistema. La eliminación de un sitio requiere la ejecución manual de dieciocho operaciones de borrado en cascada dentro de un hook del modelo, implementado mediante promesas anidadas. Si alguna de estas operaciones falla, el sistema queda en un estado de inconsistencia parcial, sin mecanismo de compensación automática. La Figura 3.1 ilustra esta centralidad de la entidad `Site` dentro del modelo monolítico.

Autenticación propietaria no estandarizada. El sistema no emplea tokens JWT ni protocolos OAuth2. En su lugar, genera cadenas aleatorias que se almacenan en una tabla `Session` de PostgreSQL, y cada petición al backend requiere una consulta a esta tabla para validar la sesión activa. Este mecanismo impide la escalabilidad horizontal y complica la integración con estándares de seguridad modernos.

Dependencias gestionadas de forma global. El archivo principal `app.js` instancia todos los componentes del sistema —conexión a base de datos, modelos ORM, servicio de correo, utilidades de cifrado— y los inyecta en un contenedor global `app.locals`, desde donde los controladores acceden directamente. Esta práctica elimina cualquier posibilidad de prueba unitaria aislada y dificulta la identificación de las dependencias reales de cada módulo.

Ausencia de prácticas de aseguramiento de calidad. El repositorio no

cuenta con un directorio de pruebas automatizadas, ni pipelines de integración continua, ni herramientas de análisis estático de código. El despliegue en producción se realiza de forma manual directamente sobre el servidor del Centro de Computación Gráfica de la Facultad de Ciencias, sin mecanismos que validen el comportamiento del sistema después de cada cambio.

Observabilidad básica. El sistema no expone endpoints de métricas, no cuenta con agregación centralizada de logs ni trazabilidad distribuida. La única forma de detectar un problema es mediante la observación directa del comportamiento de la aplicación por parte del usuario final o del mantenedor, lo que convierte el diagnóstico en un proceso enteramente reactivo y dependiente del conocimiento tácito del administrador.

En conjunto, estas deficiencias estructurales han generado un sistema cuya capacidad de adaptación es muy limitada. Cualquier modificación requiere comprender la totalidad del código, con un riesgo elevado de introducir fallos imprevistos. Esta situación, sumada a la ausencia de un equipo de desarrollo de tiempo completo y a la dependencia de colaboradores académicos temporales, exige un rediseño arquitectónico que descomponga el sistema en dominios independientes, con límites claros y mecanismos de validación automatizada.

3.1.2. Diseño de la Arquitectura de Microservicios

Para superar las limitaciones del backend monolítico, se diseñó una arquitectura basada en microservicios que descompone el sistema en dominios independientes, cada uno con responsabilidades bien definidas y desplegable de forma autónoma. Este rediseño se fundamenta en el principio de *contextos acotados*, definido en el Marco Teórico, que establece que cada servicio debe encapsular un modelo de datos y una lógica de negocio coherentes, minimizando las dependencias con los demás.

Se identificaron tres contextos fundamentales que agrupan las funcionalidades del sistema:

- **Gestión de Identidad y Acceso (UAA):** Responsable de la autenticación, autorización y emisión de tokens JWT. Centraliza la información de usuarios, roles y clientes OAuth2, permitiendo que cualquier otro servicio valide identidades sin replicar esta lógica.
- **Gestión de Sitios Académicos (Site):** Contiene la lógica de negocio central del portal: asignaturas, semestres, sitios de curso, participantes, secciones, horarios, evaluaciones, contenidos temáticos y referencias bibliográficas.
- **Servicio de Notificaciones (Notify):** Encargado del procesamiento asíncrono y despacho de correos electrónicos, desacoplando el envío de notificaciones de las operaciones síncronas de los demás servicios. El procesamiento asíncrono se materializa mediante **Apache Kafka**: los servicios publican eventos de notificación en un tópico que Notify consume para




Figura 3.1: Diagrama entidad-relación simplificado del modelo de datos monolítico, mostrando la tabla `site` como núcleo con sus dieciocho relaciones hacia entidades dependientes.

renderizar y despachar los correos, de modo que una indisponibilidad del servicio de correo no se propaga a los flujos síncronos.

El ecosistema incluye además el servicio **PAIMA**, que opera como un nodo autónomo encargado del ciclo de autogestión del mantenimiento y se detalla en la Sección 3.3.

Principio de base de datos por servicio. Cada microservicio posee su propia instancia de base de datos MySQL, aislada físicamente de las demás. Esta decisión garantiza que un cambio en el modelo de datos de un dominio no afecte a los otros, elimina el riesgo de bloqueos entre servicios y permite que cada estudiante o colaborador que forme parte del desarrollo y mantenimiento del portal pueda evolucionar el modelo de datos de un servicio sin afectar dominios no relacionados. Las bases de datos se identifican como `mysql-uaa`, `mysql-site`, `mysql-notify` y `mysql-paima`, cada una expuesta en un puerto distinto del host

para facilitar el diagnóstico local.

Configuración centralizada. Para evitar la dispersión de propiedades y secretos en múltiples archivos, se implementó un servidor de configuración basado en Spring Cloud Config Server. Este componente resuelve las propiedades de cada microservicio desde un repositorio Git local, permitiendo versionar los cambios de configuración junto al código fuente y simplificando la rotación de credenciales. Los servicios obtienen su configuración al iniciarse mediante una única variable de entorno que apunta al **Config Server**, reduciendo la complejidad del despliegue.

Punto de entrada y comunicación. El frontend de la aplicación, desarrollado en Vue.js, se sirve a través de **Nginx**, que actúa como proxy inverso enrutando las peticiones del navegador hacia los microservicios correspondientes. La comunicación interna entre los servicios se realiza directamente a través de la red virtual de Docker Compose, utilizando el nombre del contenedor como host (por ejemplo, `http://ms-uaa:5860`). Si bien un API Gateway constituye una práctica recomendada en arquitecturas de microservicios para centralizar autenticación, enrutamiento y *limitación de tasa de peticiones*, su implementación quedó fuera del alcance de este trabajo, priorizándose la funcionalidad central del ecosistema y del servicio de autogestión del mantenimiento. La Figura 3.2 presenta la vista completa del ecosistema resultante.

3.1.3. Stack Tecnológico del Backend

La selección del stack tecnológico respondió al criterio de maximizar la madurez del ecosistema, la disponibilidad de documentación y la simplicidad operativa, de forma que un colaborador académico temporal pueda comprenderlo y modificarlo sin depender de conocimiento tácito previo. Se priorizaron herramientas consolidadas, ampliamente documentadas y alineadas con los estándares de la industria, evitando la adopción de tecnologías experimentales que pudieran convertirse en pasivos técnicos.

Lenguaje y framework. Se seleccionaron **Java 17** y **Spring Boot 3** como base para todos los microservicios. Estas versiones correspondían a las *Long Term Support* (LTS) más recientes disponibles al inicio del desarrollo de este trabajo, lo que garantizó soporte extendido, estabilidad y acceso a las mejoras de rendimiento y seguridad introducidas en ambas plataformas. Aunque el monolito original utiliza Node.js y Express.js, el ecosistema Spring Boot ofrece soporte para seguridad (OAuth2 y JWT), observabilidad (Micrometer, Actuator), comunicación entre servicios (WebClient) y configuración centralizada (Config Client), lo que elimina la dependencia de bibliotecas de terceros para funcionalidades críticas del ecosistema [58]. La tipificación fuerte de Java facilita la detección temprana de errores en tiempo de compilación —como incompatibilidades de tipos en parámetros de métodos o acceso a propiedades inexistentes— que en JavaScript suelen pasar inadvertidos hasta la ejecución en producción.

Gestión de dependencias y construcción. Todos los proyectos se gestionan con **Maven**, empleando un modelo de herencia de proyectos que garantiza consistencia entre los distintos nodos del ecosistema. Se evaluó **Gradle** como alternativa de construcción; si bien ofrece tiempos de compilación inferiores y




Figura 3.2: Arquitectura del ecosistema de microservicios de PortalAsig, mostrando el proxy Nginx, el Config Server, los cuatro microservicios (UAA, Site, Notify, PAIMA), sus bases de datos MySQL aisladas, el proveedor LLM externo, el stack de observabilidad (Prometheus, Loki, Grafana) y las conexiones de monitoreo de PAIMA hacia los endpoints `/actuator/health` de cada microservicio, todo desplegado sobre la red virtual de Docker Compose.

una sintaxis declarativa basada en Kotlin, la madurez del ecosistema de plugins para Spring Boot y la experiencia previa del autor con Maven determinaron la selección de este último. Se diseñó el módulo `portalasig-commons` como biblioteca compartida, estructurado en tres artefactos:

- **core-boot**: POM padre con el *Bill of Materials* (BOM) de Spring Boot y Spring Cloud. Define las versiones de todas las dependencias del ecosistema, eliminando conflictos de versiones entre microservicios.
- **core-lib**: Código reutilizable incluyendo configuración de seguridad JWT, manejo centralizado de excepciones, serialización JSON, CORS y clientes HTTP con soporte para `client_credentials` y `bearer` tokens.
- **core-backend**: POM padre específico para microservicios backend, que hereda de `core-boot`, incluye `core-lib` y añade dependencias de persistencia (JPA, Flyway, conector MySQL), observabilidad (**Micrometer**,

Prometheus, *appender* Loki) y utilidades de compilación (**Lombok**, **MapStruct**). Se evaluó **ModelMapper** como alternativa para el mapeo entidad-DTO, pero MapStruct fue seleccionado por su generación de código en tiempo de compilación y su menor overhead en tiempo de ejecución.

Esta estructura evita la duplicación de configuración y garantiza que cualquier mejora en la seguridad, la observabilidad o el manejo de errores se propague a todos los servicios modificando únicamente el artefacto común. La Figura 3.5 ilustra el modelo de herencia resultante entre los POM del ecosistema.

Base de datos. Se evaluaron tres alternativas para el almacenamiento de datos:

- **PostgreSQL:** motor utilizado por el monolito original. Ofrece características avanzadas como tipos de datos JSON nativos, consultas geoespaciales y un optimizador de consultas robusto. Sin embargo, su configuración y operación en entornos locales de desarrollo resultan más complejas para colaboradores académicos temporales.
- **MongoDB:** base de datos NoSQL orientada a documentos que ofrece flexibilidad de schema y escalabilidad horizontal. No obstante, su modelo de datos no relacional introduce una curva de aprendizaje adicional y complica las transacciones que involucran múltiples documentos, lo cual resulta innecesario para la carga transaccional típica de un sistema académico.
- **MySQL:** motor relacional maduro, con integración nativa en Spring Boot a través del conector oficial `mysql-connector-j`, herramientas de administración accesibles y documentación extensa. Su simplicidad operativa en entornos locales la convierte en la opción más pragmática para el alcance de este proyecto.

Se seleccionó **MySQL** como motor de base de datos para todos los microservicios, manteniendo el esquema de una instancia aislada por servicio descrito en la Sección 3.1.2. La integración con Spring Boot es inmediata mediante el conector oficial, y su operación no requiere configuraciones especializadas.

Documentación de APIs. Se integró **SpringDoc OpenAPI** en todos los microservicios, lo que genera automáticamente una interfaz interactiva de documentación (**Swagger UI**) a partir de las anotaciones presentes en los controladores REST. Esta documentación viva se actualiza con cada cambio en el código, eliminando la necesidad de mantener manuales de API separados y facilitando que nuevos colaboradores comprendan los endpoints disponibles sin necesidad de leer el código fuente.

Repositorio de conocimiento del proyecto. Como complemento a la documentación de APIs, se consolidó **portalsig-pi**, un repositorio de conocimiento operativo del ecosistema que reúne guías por dominio —autenticación, sitios, notificaciones, autogestión, configuración y frontend— escritas en formato estructurado y directamente utilizable como contexto por agentes de inteligencia artificial. De esta manera, el conocimiento del proyecto no solo queda disponible para lectura humana, sino que cualquier asistente de IA puede cargarlo y

emplearlo para orientar de forma efectiva a un nuevo colaborador durante su incorporación, reduciendo la curva de aprendizaje que impone la rotación de mantenedores descrita en el primer capítulo.

Persistencia y migraciones. Se emplea **JPA** (Java Persistence API) con **Hibernate** como implementación, estándares de facto en el ecosistema Spring Boot. Esta combinación permite definir las entidades del modelo de datos como clases Java anotadas y delegar la generación de consultas SQL al framework, reduciendo la cantidad de código SQL explícito que el colaborador debe escribir y abstrayendo las diferencias de dialecto entre motores de base de datos. La migración de datos se gestiona mediante **Flyway**, que aplica scripts SQL versionados durante el arranque de cada servicio, garantizando la coherencia entre el schema de la base de datos y la versión del código desplegado. Este enfoque elimina la necesidad de ejecutar migraciones manuales y permite reproducir el estado de la base de datos en cualquier entorno a partir del repositorio de código fuente [27]. Los scripts se organizan en el directorio `src/main/resources/db/migration/` con el prefijo de versión obligatorio (`V1__`, `V2__`), lo que permite a Flyway determinar el orden de ejecución y detectar conflictos si dos colaboradores intentan crear una migración con el mismo número de versión. La Figura 3.3 ilustra la convención de directorios.




Figura 3.3: Estructura de directorios de migraciones Flyway en un microservicio.

La convención de nomenclatura sigue el formato `V{version}__{descripción}.sql`, donde cada archivo contiene sentencias DDL que construyen el esquema progresivamente. La Figura 3.4 muestra un extracto de la migración inicial del servicio Site, que define las tablas `course`, `course_semester_link`, `course_career_link` y `career`, incluyendo comentarios descriptivos en cada columna.

3.1.4. Técnicas de Mantenimiento de Software Implementadas

Una migración a microservicios no garantiza por sí sola la mantenibilidad del sistema. Es necesario incorporar prácticas sistemáticas de aseguramiento de calidad que permitan detectar problemas antes de que lleguen a producción, reducir la deuda técnica y facilitar la incorporación de nuevos colaboradores. A continuación se describen las técnicas implementadas, seleccionadas bajo el criterio de simplicidad operativa: cada herramienta debe ser configurable mediante archivos que residen en el repositorio de código, sin requerir servidores

```

1 CREATE TABLE course
2 (
3   course_id INT NOT NULL AUTO_INCREMENT COMMENT 'primary key, auto increment',
4   code VARCHAR(120) NOT NULL COMMENT 'Course code. Serves as a Identifier',
5   name VARCHAR(120) NOT NULL COMMENT 'Course name',
6   credit_units SMALLINT UNSIGNED NOT NULL COMMENT 'Number of credit units',
7   type VARCHAR(120) NOT NULL COMMENT 'Course type',
8   course_level VARCHAR(120) NOT NULL COMMENT 'Course level where is required: Semester 1st, 2nd, etc...',
9   requirements VARCHAR(120) COMMENT 'Course requirements',
10  created_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP COMMENT 'date and time this row was created',
11  updated_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP ON UPDATE CURRENT_TIMESTAMP COMMENT 'date and time this row was last updated',
12  PRIMARY KEY (course_id),
13  UNIQUE KEY (code),
14  KEY course_id_idx (type)
15 ) COMMENT 'A course that is offered by college';
16
17 CREATE TABLE course_semester_link
18 (
19   course_semester_link_id INT NOT NULL AUTO_INCREMENT COMMENT 'primary key, auto increment',
20   course_id INT NOT NULL COMMENT 'course ID',
21   semester_id INT NOT NULL COMMENT 'Semester ID',
22   created_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP COMMENT 'date and time this row was created',
23   updated_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP ON UPDATE CURRENT_TIMESTAMP COMMENT 'date and time this row was last updated',
24   PRIMARY KEY (course_semester_link_id)
25 ) COMMENT 'A course that is offered in a semester';
26
27 CREATE TABLE course_career_link
28 (
29   course_career_link_id INT NOT NULL AUTO_INCREMENT COMMENT 'primary key, auto increment',
30   course_id INT NOT NULL COMMENT 'course ID',
31   career_id INT NOT NULL COMMENT 'career ID',
32   created_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP COMMENT 'date and time this row was created',
33   updated_date TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP ON UPDATE CURRENT_TIMESTAMP COMMENT 'date and time this row was last updated',
34   PRIMARY KEY (course_career_link_id)
35 ) COMMENT 'Join table between course and career';
36
37 CREATE TABLE career
38 (
39   career_id INT NOT NULL AUTO_INCREMENT COMMENT 'Career ID',

```

Figura 3.4: Extracto del script de migración inicial V1.0.0.00__init.sql del servicio Site, mostrando la definición de tablas con sentencias `CREATE TABLE` y comentarios de columnas.

adicionales ni infraestructura dedicada.

Se integró **Checkstyle** en el artefacto `core-boot` con el perfil `google_checks.xml`, ejecutándose durante la compilación de Maven en todos los microservicios. La compilación se interrumpe si el código incumple reglas de estilo, impidiendo que código inconsistente llegue al repositorio. Se optó por Checkstyle sobre SpotBugs porque la prioridad del proyecto era garantizar la legibilidad y uniformidad del código fuente, aspectos críticos cuando múltiples colaboradores rotativos modifican el mismo código.

Se configuró **GitHub Actions** como pipeline de integración continua en cada repositorio, ejecutando en secuencia: compilación, Checkstyle, pruebas de integración y generación del reporte de cobertura. Las ramas principales están protegidas mediante *branch protection*, bloqueando el envío directo de código y exigiendo que todo cambio llegue mediante un *pull request* que pase exitosamente la pipeline antes de su fusión. Se optó por GitHub Actions sobre Jenkins porque este último requiere un servidor propio y mantenimiento de infraestructura, mientras que GitHub Actions se define mediante archivos YAML en el mismo repositorio y ejecuta sobre los servidores de GitHub sin costo adicional.

Se incorporó **JaCoCo** como plugin de Maven para medir la cobertura de líneas y ramas durante la ejecución de los tests, generando un reporte HTML detallado por paquete, clase y método. Se configuró un umbral mínimo del setenta por ciento de líneas y sesenta por ciento de ramas en el workflow de GitHub Actions, de forma que la compilación falla automáticamente si la cobertura desciende por debajo de los valores establecidos. Se eligió JaCoCo sobre SonarQube porque este último requiere un servidor dedicado con base de datos propia, mientras




Figura 3.5: Diagrama de herencia de dependencias Maven.

que JaCoCo produce el reporte como parte del proceso de compilación.

Las pruebas de integración se implementaron con **Testcontainers**, que levanta contenedores Docker efímeros de MySQL 8 durante la fase de pruebas de Maven. La clase base **AbstractMySQLIntegrationTest** instancia la base de datos, ejecuta las migraciones Flyway y destruye el contenedor al finalizar, garantizando que las pruebas validen el comportamiento real sobre un motor idéntico al de producción [35]. La evolución de la suite de integración, los escenarios cubiertos y las lecciones aprendidas en su construcción se documentan en el Capítulo 4.

Para las pruebas end-to-end se empleó **Cypress**, que ejecuta los tests dentro del mismo ciclo de vida del navegador, simulando flujos completos del usuario: inicio de sesión, navegación por sitios de asignatura y gestión de contenidos. Los tests realizan peticiones directas de login contra el servicio UAA para obtener el token JWT, inyectándolo en las peticiones subsecuentes [40].

El stack de observabilidad se configuró con **Prometheus** para métricas, **Loki** para agregación de logs y **Grafana** para visualización unificada [31, 32]. Estas herramientas se definieron en el Marco Teórico (Sección 2.3.5) y se integraron en cada microservicio mediante el artefacto **core-lib**. **SpringDoc OpenAPI**

genera documentación interactiva de los endpoints REST a partir de las anotaciones de los controladores, eliminando la necesidad de mantener manuales separados. La Figura 3.6 muestra la exploración centralizada de logs del servicio Site mediante Grafana sobre los registros agregados por Loki.




Figura 3.6: Exploración de logs con Grafana y Loki durante el arranque del ecosistema de microservicios.

3.1.5. Despliegue, Gestión y Migración de Datos

Para la gestión del ecosistema en entornos de desarrollo se seleccionó **Docker Compose**, que permite describir todo el ecosistema —bases de datos, microservicios, componentes de observabilidad y frontend— en un único archivo declarativo y levantarlo mediante un comando único. Frente a alternativas como Kubernetes, Docker Compose ofrece simplicidad operativa para entornos sin requisitos de autoescalado ni alta disponibilidad multi-nodo, lo cual resulta adecuado para el contexto de servidores universitarios *on-premise* [14]. Se desarrolló el script **portalasig-cli** para encapsular las operaciones más frecuentes: preparación inicial del entorno (**bootstrap**), levantamiento (**up**), detención ordenada (**down**) y visualización de logs por servicio (**logs**).

El monolito original utiliza una única base de datos PostgreSQL con un schema centralizado donde la tabla **site** actúa como núcleo con dieciocho relaciones hacia entidades dependientes. En la arquitectura de microservicios se adoptó el principio de un schema aislado por servicio: UAA gestiona identidades y roles; Site administra cursos, semestres, participantes y contenidos académicos; y Notify registra eventos de correo. Esta redistribución elimina el acoplamiento referencial entre dominios —las referencias cruzadas entre servicios se convierten

en referencias lógicas sin clave foránea— y permite que cada servicio evolucione su modelo de forma independiente mediante **Flyway**. La Figura 3.7 resume el modelo de datos distribuido resultante.




Figura 3.7: Modelo de datos distribuido del ecosistema: esquemas aislados por servicio, con claves foráneas reales dentro de cada dominio y referencias lógicas (sin clave foránea) entre dominios.

Para facilitar el desarrollo y las pruebas se diseñó el repositorio **portalasig-seeding**, que orquesta la carga de datos de prueba mediante invocación de endpoints REST de carga masiva expuestos por cada microservicio. El módulo utiliza una migración anonimizada de la base de datos de producción, donde los campos sensibles se sustituyen por valores aleatorios que preservan el formato y la cardinalidad originales. Esta estrategia garantiza que cada instancia del ecosistema comience con un estado conocido y reproducible, facilitando la validación de flujos de negocio bajo condiciones que emulan la operación real sin exponer información personal.

3.2. Comparativa Cualitativa: Monolito vs. Microservicios

La migración de una arquitectura monolítica a una de microservicios introduce cambios sustanciales en múltiples dimensiones del ciclo de vida del software. A continuación se presenta un análisis comparativo cualitativo que contrasta ambos enfoques en las dimensiones más relevantes para el contexto operativo de PortalAsig.

La Tabla 3.1 evidencia que la arquitectura de microservicios mejora las capacidades de despliegue, aislamiento, observabilidad y testing. Sin embargo, este beneficio no es gratuito: introduce una complejidad operativa que el equipo debe gestionar. En el contexto de PortalAsig, donde no existe un equipo de operaciones dedicado, esta complejidad se aborda de forma circular: la misma arquitectura distribuida que genera el problema —múltiples servicios que pueden fallar de forma independiente— proporciona también los instrumentos para resolverlo. El stack de observabilidad (Prometheus, Loki, Grafana) instalado para monitorear los microservicios no es un fin en sí mismo: constituye la

Dimensión	Monolito	Microservicios
Despliegue	Redespliegue completo obligatorio ante cualquier cambio, con tiempo de indisponibilidad proporcional al tamaño de la aplicación.	Despliegue independiente por servicio. Un cambio en la gestión de evaluaciones no requiere tocar el servicio de autenticación.
Aislamiento de fallos	Un error en cualquier módulo compromete la estabilidad de toda la aplicación.	Un servicio caído aísla el fallo al dominio que gestiona. El resto del ecosistema continúa operativo.
Observabilidad	Logs básicos del proceso Node.js consultables mediante <code>pm2</code> , sin métricas estructuradas, sin agregación centralizada de logs ni trazabilidad distribuida. El diagnóstico es reactivo y manual.	Stack completo: Prometheus recolecta métricas, Loki agrega logs, Grafana visualiza correlaciones. El diagnóstico es proactivo y centralizado.
Testing	Sin tests automatizados, sin cobertura medida y sin pipelines de validación. Cada cambio se prueba manualmente en producción.	Tests de integración con Testcontainers sobre MySQL real, cobertura con JaCoCo, E2E con Cypress, y validación automática en cada <i>pull request</i> mediante la configuración de GitHub Actions y las reglas de protección de ramas (<i>branch protection</i>), que bloquean la fusión si los checks no pasan.
Complejidad operativa	Baja. Un único proceso, una única base de datos, un único despliegue.	Mayor. Múltiples procesos, múltiples bases de datos, orquestación con Docker Compose, resolución de dependencias de red.

Cuadro 3.1: *Comparativa cualitativa: arquitectura monolítica vs. microservicios*

infraestructura sobre la cual opera el servicio PAIMA, que asume la función de operador autónomo y reduce la carga cognitiva sobre el colaborador temporal.

De este modo, PAIMA no es un componente aislado ni una funcionalidad adicional disponible sobre cualquier arquitectura: es un caso de uso directo y consecuencia lógica de la migración a microservicios. En el monolito, un único proceso con un único log impide cualquier forma de observabilidad distribuida; sin métricas por servicio ni agregación centralizada de logs, no existe material sobre el cual un sistema de autogestión pueda razonar. La descomposición en dominios independientes, junto con la instrumentación de cada nodo, habilita por primera vez la posibilidad de detectar, diagnosticar y actuar sobre fallas de forma automatizada.

Estas tres capacidades —distribución arquitectónica, observabilidad instrumentada y acción autónoma— constituyen las propiedades convergentes del paradigma de la Web 3.0 tal como se definió en el Marco Teórico. El monolito de PortalAsig, concebido bajo los principios de la Web 2.0, podía procesar información y facilitar la interacción entre usuarios, pero carecía de los mecanismos necesarios para adaptarse, auto-diagnosticarse o incorporar capacidades inteligentes. La arquitectura de microservicios documentada en esta sección no resuelve únicamente los problemas de acoplamiento y mantenibilidad: establece la infraestructura material sobre la cual el sistema puede evolucionar hacia un

modelo distribuido, observable y autogestionado, alineado con las exigencias de la Web 3.0.

3.3. Servicio PAIMA — Autogestión del Mantenimiento Asistido por IA

El servicio PAIMA constituye un caso de uso concreto de la arquitectura de microservicios descrita en la sección anterior: solo es posible porque el desacoplamiento en servicios independientes permite instrumentar cada nodo con métricas y logs, y porque la observabilidad distribuida proporciona el material técnico sobre el cual un sistema de autogestión puede razonar. En este sentido, PAIMA no es una funcionalidad aislada ni un componente opcional, sino la demostración operativa de las capacidades que la arquitectura distribuida habilita. A continuación se describe su motivación, su arquitectura interna, el funcionamiento de cada fase del ciclo MAPE-K y la interfaz de gestión de incidentes implementada en el frontend.

3.3.1. Motivación y Contexto

La migración a microservicios resuelve el problema del acoplamiento arquitectónico del monolito, pero introduce una nueva complejidad operativa: un ecosistema distribuido tiene múltiples puntos de fallo, cada servicio expone sus propias métricas y logs, y la correlación de problemas entre nodos requiere observar simultáneamente múltiples fuentes de datos. En un entorno donde no hay operadores dedicados de forma permanente, donde el mantenimiento recae en colaboradores académicos temporales que deben dividir su atención entre el desarrollo de nuevas funcionalidades y la resolución de incidencias, esta complejidad puede convertirse en un cuello de botella crítico. Frente a esta situación, la arquitectura misma suministra la solución: el stack de observabilidad instalado para monitorear los microservicios se convierte en la base sobre la cual PAIMA ejecuta su ciclo de control.

Este servicio, denominado **PAIMA** (**P**ortal**A**sig **I**ntelligent **MAPE-K**), implementa un ciclo de autogestión del mantenimiento inspirado en el modelo MAPE-K, pero con la diferencia crítica de que las fases de Análisis y Planificación se delegan a un modelo de inteligencia artificial externo. Tal como se documentó en el Marco Teórico (Sección 2.6.2), esta decisión se alinea con la dirección de investigación que integra MAPE-K con inteligencia artificial para la gestión autónoma de microservicios [3]. PAIMA constituye una implementación práctica de este framework adaptada a las limitantes operativas del contexto de PortalAsig. PAIMA no opera sobre una infraestructura abstracta: sus conectores de monitoreo apuntan específicamente a las instancias de Prometheus y Loki desplegadas junto a los microservicios documentados en la Sección 3.1.2, y sus acciones de remediación invocan directamente los contenedores gestionados por Docker Compose descritos en la Sección 3.1.5. En este sentido, PAIMA es un caso de uso

directo de la arquitectura de microservicios: solo la existencia de un ecosistema distribuido e instrumentado hace posible su implementación.

3.3.2. Arquitectura Interna de PAIMA

PAIMA se implementó como un microservicio Spring Boot con un *scheduler* periódico que ejecuta el ciclo MAPE-K definido en el Marco Teórico. La arquitectura de clases se organiza en paquetes que reflejan las fases del ciclo: **monitor**, **analyze**, **plan**, **execute** y **knowledge**. Cada paquete encapsula las interfaces y servicios que permiten sustituir implementaciones sin afectar al resto del sistema. La Figura 3.8 presenta el diagrama de clases resultante, organizado por las fases del ciclo.

La integración con el proveedor de inteligencia artificial se abstrae mediante la interfaz `PaimaAiProvider`, que cuenta con tres implementaciones: `OpenAiCompatiblePaimaAiProvider`, para APIs remotas compatibles con OpenAI (OpenAI, Gemini u otros proveedores de esa familia); `OllamaPaimaAiProvider`, para modelos locales ejecutados mediante Ollama; y `RuleBasedPaimaAiProvider`, un mecanismo de fallback determinista basado en reglas que prioriza incidencias sin intervención de un modelo externo —prioridad P1 para servicios fuera de servicio y P2 para patrones de error en los registros o para objetivos de monitoreo caídos—. El proveedor activo se selecciona mediante el Config Server; ante una configuración ausente o no válida, el sistema degrada automáticamente al proveedor basado en reglas, de modo que el ciclo de autogestión conserva capacidad de análisis aun sin disponibilidad de un modelo de lenguaje. La orquestación del ciclo completo la coordina la clase `PaimaMapeScheduler`, invocada mediante la anotación `@Scheduled` de Spring con una frecuencia configurable a través del Config Server. Adicionalmente, PAIMA expone endpoints REST bajo el prefijo `/paima` —`/paima/alerts` para la gestión de alertas, `/paima/mape` para la inspección del estado del ciclo y `/paima/llm/chat` para el asistente conversacional— que permiten a la interfaz de usuario consultar alertas activas, registrar decisiones humanas y auditar el historial de incidentes.

Un aspecto distintivo de la arquitectura es la persistencia del conocimiento generado en cada iteración del ciclo. No basta con almacenar la alerta y su resolución: el sistema conserva el `MonitoringSnapshot` completo, el plan de acción propuesto por el modelo de IA, la decisión humana (aprobación o rechazo) y los comentarios asociados. Este registro acumulativo, almacenado en las tablas `paima_alert` y `paima_alert_feedback`, constituye una base de conocimiento operativo que puede compactarse y reinyectarse en iteraciones futuras. A medida que el sistema opera, el historial de incidentes resueltos permite ajustar los umbrales de detección, refinar los *prompts* enviados al modelo de IA e identificar patrones recurrentes de fallo, transformando la fase Knowledge de un simple repositorio de registros en un mecanismo de mejora continua del propio servicio de autogestión.




Figura 3.8: Diagrama de clases de PAIMA mostrando los paquetes del ciclo MAPE-K.

3.3.3. Fase Monitor: Recolección de Datos Operativos

Durante la monitorización, el sistema centraliza la telemetría operativa. Efectúa consultas a las plataformas de agregación de métricas (Prometheus) para evaluar el estado de salud, carga de la infraestructura y tasas de respuesta. Simultáneamente, consulta el motor de registros (Loki) para consolidar excepciones,

errores en tiempo de ejecución o advertencias críticas. Los enlaces de conexión hacia estos monitores se inyectan a través de variables de entorno, dotando a la herramienta de total portabilidad e independencia de infraestructura específica.

3.3.4. Fase Analyze y Plan: Asistencia con Inteligencia Artificial

Una vez consolidadas las métricas y los logs de todas las fuentes de monitoreo, PAIMA evalúa si las condiciones del ecosistema indican una anomalía que requiera intervención. Los criterios de detección incluyen servicios sin respuesta (`DOWN`), latencias superiores a los umbrales configurados en Prometheus, o un volumen inusual de excepciones registradas en Loki. Cuando se supera alguno de estos umbrales, el sistema compone un informe que agrupa el estado de salud de cada servicio, las métricas numéricas relevantes y los fragmentos de log asociados, y lo envía al modelo de inteligencia artificial.

La integración con el proveedor de IA se abstrae mediante una interfaz interna que permite sustituir el modelo subyacente —ya sea un servicio local de bajo consumo (Ollama) o una API remota (OpenAI, Gemini)— sin modificar la lógica de orquestación. El modelo recibe el informe consolidado, identifica la causa probable del problema y responde con un plan de acción estructurado que incluye una prioridad (P1 crítica, P2 moderada, P3 informativa), un modo de ejecución (semi-asistido o autónomo) y una estrategia concreta de remediación, como reiniciar el servicio afectado, revisar el código fuente o notificar a los administradores del sistema.

3.3.5. Fase Execute: Automatización y Notificación

En la fase de ejecución, PAIMA procesa las acciones recomendadas por el modelo de IA. El modo de ejecución declarado en cada plan determina si la acción requiere aprobación humana previa (*semi-asistido*) o si PAIMA la ejecuta directamente (*autónomo*); en la configuración validada en este trabajo, las acciones de remediación sobre servicios operan en modo semi-asistido, de modo que toda intervención sobre el ecosistema cuenta con aprobación humana explícita. Las acciones pueden ser de dos tipos principales:

- **Acciones sobre el entorno:** PAIMA puede ejecutar comandos directamente sobre el entorno Docker. Por ejemplo, para un reinicio de servicio, invoca el script `portalsig-cli` con el comando `restart` para el microservicio objetivo.
- **Notificaciones:** Para acciones que requieren intervención humana o simplemente informar, PAIMA publica un evento de notificación en el tópico de **Apache Kafka** consumido por el microservicio `ms-notify`, que renderiza y despacha el correo electrónico a los administradores del sistema, incluyendo detalles del incidente y las recomendaciones de la IA.

Cada acción, ya sea automática o de notificación, es registrada en la base de datos de PAIMA, manteniendo un historial completo.

3.3.6. Fase Knowledge: Registro de Incidentes y Retroalimentación

Todo el estado, los planes propuestos por la IA y la evidencia de las fallas se almacenan en una base de datos relacional (tablas `paima_alert` y `paima_alert_feedback`). Esta persistencia actúa como la base de Conocimiento (Knowledge) del modelo MAPE-K. Los administradores interactúan con estas alertas para aprobar o rechazar acciones. Estas decisiones humanas, acompañadas de comentarios, se retroalimentan en el sistema. A futuro, este registro continuo de incidentes y decisiones permitirá perfeccionar los prompts o realizar fine-tuning del modelo de IA, logrando un proceso de auto-mantenimiento más autónomo y robusto.

La operación del ciclo MAPE-K se complementa con una interfaz de gestión de incidentes integrada en el frontend de PortalAsig, que permite al administrador visualizar alertas, consultar evidencia consolidada, interactuar con el asistente de IA y aprobar acciones de remediación. La descripción técnica de esta interfaz se presenta en el Capítulo 4, dentro de la sección dedicada a la validación del sistema de autogestión del mantenimiento.

3.4. Adaptación del Frontend a la Arquitectura Distribuida

El frontend de PortalAsig, desarrollado originalmente en Vue.js 2 y rediseñado por Vásquez Balza [1], operaba como cliente de un único backend monolítico. Con la migración a microservicios, la capa de presentación requirió una reestructuración arquitectónica para comunicarse con múltiples servicios independientes, gestionar la autenticación JWT/OAuth2 y mantener la coherencia de la interfaz de usuario sin incrementar la complejidad cognitiva del desarrollador.

3.4.1. Diagnóstico del Frontend Legacy

El código heredado presentaba una arquitectura de store monolítica: un único archivo `store.js` concentraba todo el estado de la aplicación —usuarios, cursos, sitios, configuración de administración— sin separación por dominio. La comunicación con el backend se realizaba mediante una única instancia de Axios apuntando a un endpoint `VUE_APP_API_URL`, lo que asumió un backend único y centralizado. La autenticación empleaba un mecanismo propietario basado en `localStorage`, almacenando un token de sesión generado por el monolito e inyectándolo en cada petición mediante un encabezado con nombre custom.

La estructura de carpetas era plana: componentes genéricos (`TheHeader.vue`, `TheFooter.vue`) convivían con vistas de páginas completas (`HomePage.vue`, `SitePage.vue`) sin jerarquía de dominio. No existía configuración de linting ni formateo automatizado, lo que generaba inconsistencias de estilo y dificultaba la lectura del código para nuevos colaboradores. Finalmente, el router definía guards de navegación con siete niveles de permisos pero se encontraba acoplado en un

único archivo monolítico junto a todas las rutas de la aplicación, dificultando su mantenimiento y extensión.

3.4.2. Reestructuración Arquitectónica

Se realizó un refactor progresivo que preservó la funcionalidad existente mientras se adaptaba la base de código a estándares de calidad y modularidad.

Modularización del store Vuex. El estado se descompuso en cinco módulos independientes: **base** (configuración global), **course** (asignaturas), **session** (autenticación y tokens), **site** (sitios académicos) y **user** (perfiles y permisos). Cada módulo encapsula su propio estado, mutaciones, acciones y getters, eliminando el acoplamiento entre dominios que provocaba efectos colaterales en el store monolítico.

Router modular con guards de navegación. Las rutas se organizaron en archivos separados por dominio (**home.js**, **login.js**, **admin.js**, **site.js**, **userSettings.js**), manteniendo los siete niveles de guards existentes (**requiresAuth**, **requiresAnonymous**, **requiresStudentOrBetter**, **requiresTeachingStaffPermission**, **requiresStudentTeacherOrBetter**, **requiresCoordOrBetter** y **requiresAdmin**). Esta descomposición eliminó el acoplamiento del router monolítico y permitió que cada guard evolucionara de forma aislada en el módulo de su dominio, preservando la autorización por rol sin depender de un único archivo centralizado.

Múltiples instancias de Axios. Se reemplazó la instancia única de Axios por tres clientes independientes en **src/config/global-axios.js**: **uaaService**, **siteService** y **paimaService**. Cada uno apunta a la URL base de su micro-servicio correspondiente y gestiona el encabezado **Authorization** de forma aislada. Este diseño refleja directamente la topología del backend distribuido en el frontend.

Organización de componentes por dominio. Los componentes se agruparon en carpetas funcionales: **base/** (**TheHeader**, **TheFooter**), **course/** (formularios de asignatura), **user/** (perfil, preferencias) y **ValidationFeedback.vue** como componente reusable de validación de formularios. Las vistas pasaron de nombres genéricos (**HomePage.vue**) a nombres descriptivos por función (**home/Home.vue**, **site/Site.vue**).

Estándar de calidad de código. Se incorporaron ESLint 7, Prettier y **vue-eslint-parser** como dependencias de desarrollo. El script **serve** ejecuta linting antes de levantar el servidor de desarrollo, y **npm run format** aplica correcciones automáticas. Esta configuración eliminó las inconsistencias de estilo y estableció un estándar reproducible para futuros colaboradores.

3.4.3. Migración de Autenticación

La autenticación se migró del mecanismo propietario del monolito al flujo OAuth2/JWT implementado por el servicio UAA. El frontend ahora ejecuta un flujo de dos pasos que separan la identidad de la aplicación cliente de la identidad del usuario final.

En el primer paso, el frontend se autentica como aplicación cliente registrada mediante el flujo `client_credentials`: envía su `client_id` y `client_secret` al endpoint `/oauth/token` del servicio UAA y recibe un *access token* anónimo con alcance limitado a operaciones públicas (por ejemplo, consulta de asignaturas o semestres activos). Este token no contiene información de identidad de usuario, pero permite que el servidor trace y limite las peticiones de la aplicación.

En el segundo paso, cuando el usuario ingresa sus credenciales, el frontend intercambia el token anónimo (o las credenciales directamente, según el flujo configurado) por un *access token* JWT vinculado al usuario, que incluye *claims* de identidad, roles y tiempo de expiración. Junto a este token, UAA emite un `refresh_token` de mayor duración. El frontend almacena ambos valores en cookies (mediante `js-cookie`) en lugar de `localStorage`, mejorando la seguridad contra ataques XSS y permitiendo que el navegador gestione la expiración de forma declarativa.

El módulo `session` implementa un mecanismo automático de refresco: antes de que expire el *access token*, el frontend envía el `refresh_token` al endpoint `/v1/auth/refresh-token` de UAA y recibe un nuevo par de tokens sin interrumpir la sesión del usuario ni solicitar la contraseña nuevamente [21, 22].

3.4.4. Integración con los Microservicios

La migración de endpoints implicó mapear cada operación del frontend hacia el servicio correspondiente: autenticación y gestión de usuarios hacia UAA (`/v1/user/`, `/v1/auth/`), operaciones de sitios académicos hacia Site (`/v1/site/`, `/v1/semester/`), y alertas de mantenimiento hacia PAIMA (`/paima/alerts`). El router se configuró en modo `history`, eliminando el prefijo `/#/` de las URLs y produciendo rutas limpias compatibles con el proxy inverso de Nginx.

La configuración de CORS en cada microservicio permite que el frontend Vue.js, servido desde el contenedor `frontend` de Docker Compose, realice peticiones cruzadas hacia `ms-uaa`, `ms-site` y `paima`. La comunicación interna entre el frontend y los microservicios se enruta a través de Nginx, que actúa como proxy inverso y centraliza el punto de entrada del ecosistema.

La Tabla 3.2 resume las transformaciones principales. Esta adaptación no alteró la experiencia visual del usuario final —la interfaz conserva el diseño institucional y los flujos de navegación establecidos— pero cambió radicalmente su arquitectura interna, alineándola con la topología distribuida del nuevo backend.

Dimensión	Frontend Legacy	Frontend Adaptado
Arquitectura de estado	Store Vuex monolítico, un único archivo.	Store modular por dominio (5 módulos independientes).
Comunicación backend	Única instancia Axios a un endpoint.	Tres instancias Axios (UAA, Site, PAIMA).
Autenticación	Sesiones propietarias en <code>localStorage</code> .	OAuth2/JWT con cookies y refresh token.
Autorización	Router monolítico con guards acoplados.	Router modular con guards desacoplados por dominio.
Calidad de código	Sin linting ni formateo.	ESLint + Prettier con verificación automática.
Estructura	Carpetas planas, nombres genéricos.	Componentes por dominio, vistas descriptivas.

Cuadro 3.2: *Comparativa cualitativa: frontend monolítico vs. frontend adaptado*

Capítulo 4

Pruebas y Resultados

La migración a microservicios y la implementación del servicio PAIMA introducen cambios sustanciales tanto en la arquitectura como en la forma de operar el sistema. No basta con construir el ecosistema: es necesario demostrar que los mecanismos de aseguramiento de calidad funcionan, establecer un marco reproducible para la evaluación del rendimiento frente al monolito legacy, y verificar que el ciclo de autogestión del mantenimiento detecta y resuelve fallas de forma efectiva. Este capítulo documenta la estrategia de pruebas diseñada, los escenarios ejecutados y los resultados obtenidos, organizados en cuatro dimensiones: cobertura de código, validación end-to-end, rendimiento bajo carga y resiliencia ante fallos.

4.1. Metodología y Entorno de Pruebas

Todas las pruebas se ejecutaron sobre el ecosistema completo desplegado mediante Docker Compose en una estación de trabajo local. El único requisito para reproducir los resultados es contar con Docker y Docker Compose instalados; no se necesita infraestructura adicional ni servicios externos configurados, salvo el proveedor de IA que PAIMA utilice en la instalación particular.

Se definieron cuatro categorías de prueba:

- **Pruebas de integración:** Validan el comportamiento de capas de persistencia, repositorios JPA y controladores REST sobre instancias reales de MySQL 8 gestionadas por Testcontainers.
- **Pruebas end-to-end:** Simulan flujos completos del usuario final mediante Cypress, verificando que la interfaz responde correctamente ante operaciones de autenticación, navegación y gestión de contenidos.
- **Benchmarking de rendimiento:** Mide latencia, throughput y uso de recursos bajo cargas sintéticas mediante herramientas de generación de tráfico HTTP.

- **Ingeniería del caos:** Introduce fallos controlados en servicios específicos para validar la capacidad de detección y recuperación de PAIMA.

Para cada categoría se establecieron métricas objetivo, herramientas de medición y umbrales de aceptación. La Tabla 4.1 resume esta instrumentación.

Categoría	Métrica objetivo	Herramienta	Umbral de aceptación
Integración	Cobertura de líneas y ramas	JaCoCo + GitHub Actions	70 % de líneas, 60 % de ramas
End-to-end	Tasa de éxito de la suite	Cypress	100 % en ejecuciones consecutivas
Rendimiento	Latencia p95/p99, throughput, tasa de error	k6 + Prometheus	Comparativo frente al monolito
Resiliencia	Detección y recuperación ante fallo inyectado	PAIMA + Grafana	Detección dentro de un ciclo de monitoreo

Cuadro 4.1: *Métricas objetivo, herramientas de medición y umbrales de aceptación por categoría de prueba*

4.2. Pruebas de Integración y Cobertura de Código

La validación del backend distribuido se estructuró en dos líneas complementarias: pruebas de integración que verifican el comportamiento real de cada microservicio sobre instancias de base de datos idénticas a las de producción, y mediciones de cobertura de código que cuantifican el grado de ejercitación de las rutas de negocio. Ambas actividades se integran en un pipeline de integración continua que ejecuta la suite completa en cada cambio del repositorio, bloqueando la fusión de código que no cumpla los umbrales establecidos. A continuación se describe la estrategia de pruebas sobre contenedores reales, seguida del análisis de cobertura obtenido con JaCoCo y la configuración del workflow automatizado.

4.2.1. Estrategia de Pruebas de Integración

Se priorizó la ejecución de pruebas de integración sobre bases de datos reales en lugar de *mocks* o bases de datos en memoria. La clase base `AbstractMysqlIntegrationTest`, incluida en el artefacto `core-lib`, levanta un contenedor Docker de MySQL 8 antes de cada test, ejecuta las migraciones Flyway correspondientes y destruye el contenedor al finalizar. Este enfoque garantiza que las pruebas validen comportamientos que dependen del dialecto SQL real, como las restricciones de clave foránea, las transacciones concurrentes y las secuencias de generación de identificadores.

Las pruebas cubren los siguientes escenarios críticos por microservicio:

- **UAA:** Creación y autenticación de usuarios, emisión de tokens JWT, validación de roles y expiración de sesiones.
- **Site:** Creación de cursos, inscripción de participantes, generación de secciones y horarios, validación de restricciones de unicidad en evaluaciones.
- **Notify:** Encolado de eventos de correo, renderizado de plantillas y confirmación de despacho.
- **PAIMA:** Detección de anomalías simuladas, generación de alertas y persistencia de decisiones humanas.

4.2.2. Cobertura de Código con JaCoCo

Se configuró JaCoCo en cada microservicio para medir la cobertura de líneas y ramas durante la ejecución de los tests de integración. El reporte se genera en `target/site/jacoco/` y se integra con GitHub Actions de forma que la pipeline falla automáticamente si la cobertura global desciende por debajo del umbral establecido. Los resultados obtenidos se resumen en la Tabla 4.2.

Microservicio	Cobertura de líneas	Cobertura de ramas
UAA	84.6 %	64.4 %
Site	80.5 %	61.3 %
Notify	91.8 %	71.4 %
PAIMA	85.5 %	78.6 %

Cuadro 4.2: Cobertura de código por microservicio (líneas y ramas)

Las ramas principales de cada repositorio están protegidas mediante *branch protection*, que exige que todos los checks de la pipeline pasen exitosamente antes de permitir la fusión del código. Cuando un colaborador abre un pull request, el workflow de GitHub Actions se dispara automáticamente y el botón de merge permanece deshabilitado mientras el check “Build and Verify Services” se encuentra en ejecución, mostrando el estado *“Some checks haven’t completed yet”* junto con la opción “Enable auto-merge”. La Figura 4.1 ilustra esta condición de bloqueo en el pull request del servicio Site.

Durante el tiempo de bloqueo, el workflow ejecuta en secuencia la compilación de dependencias, el análisis de Checkstyle, las pruebas de integración con Testcontainers, la generación del reporte JaCoCo y la verificación del umbral mínimo de cobertura. La Figura 4.2 muestra el pipeline del servicio Site en ejecución, con los pasos iniciales completados y el paso intermedio activo.

Una vez que todos los pasos —checkstyle, tests, JaCoCo y verificación de cobertura— finalizan sin errores, el check se marca como *“Required”* con resultado exitoso, el mensaje cambia a *“All checks have passed”* y la integración queda habilitada. La Figura 4.3 muestra el pull request del servicio Site tras la finalización exitosa del workflow, con el check validado y el merge disponible.




Figura 4.1: Pull request bloqueado mientras el workflow de GitHub Actions se encuentra en ejecución. El check “Build and Verify Services” aparece como requerido y el merge permanece deshabilitado hasta su finalización.

Se estableció un umbral mínimo del 70 % para cobertura de líneas y del 60 % para cobertura de ramas en todos los microservicios, valores que el ecosistema cumple o supera. El valor más elevado, el de Notify, responde a la menor complejidad de su dominio, centrado en el renderizado de plantillas y el despacho de eventos. PAIMA y UAA le siguen de cerca: en el caso de PAIMA, la cobertura se apoya en tests unitarios sobre los componentes desacoplados del ciclo MAPE-K (colector de observabilidad, planificador de IA y gateways de los proveedores de lenguaje), verificados con dobles de prueba que sustituyen las dependencias externas. Site, al concentrar la lógica de negocio principal del portal, requirió el mayor esfuerzo de pruebas para alcanzar el umbral, incluyendo tests sobre restricciones de unicidad, cascadas de persistencia y validaciones de reglas de negocio. PAIMA, por su parte, complementa su suite —cuyos valores de cobertura se reportan en la Tabla 4.2— con la inyección de anomalías simuladas que ejercitan las cuatro fases del ciclo MAPE-K, documentada en la Sección 4.5. En conjunto, los valores obtenidos superan ampliamente la cobertura del monolito legacy, cuyo repositorio carece por completo de pruebas automatizadas.

Evolución de la suite de integración. La cobertura no se alcanzó en una única iteración. Durante las primeras semanas de desarrollo, la suite contaba




Figura 4.2: Ejecución del workflow de GitHub Actions para el servicio Site, mostrando los pasos de compilación, pruebas de integración y verificación de cobertura.

con tests básicos de creación y consulta sobre cada entidad. A medida que se identificaron casos de borde —restricciones de unicidad violadas, cascadas de eliminación inconsistentes, transacciones concurrentes sobre la misma entidad— se fueron agregando tests específicos que ejercitan estos escenarios. Este proceso iterativo de “testear, fallar, corregir, verificar” transformó la suite de una colección de verificaciones simples en una red de seguridad que captura regresiones antes de que afecten al código base. Cabe destacar que la propia suite expuso defectos reales del código de producción, todos corregidos tras su detección. En el servicio Site, la eliminación de un sitio con evaluaciones asociadas podía dejar registros huérfanos debido a un mapeo incorrecto de la relación entre entidades, lo que motivó un test de integración que verifica la eliminación en cascada; en el mismo servicio, la importación masiva de estudiantes fallaba con una excepción de puntero nulo cuando el sitio aún no tenía secciones registradas, y varios endpoints presentaban el mismo tipo de fallo al operar sobre sitios sin participantes ni horarios. También en Site se detectó que los valores por defecto declarados en los objetos de solicitud (prioridad y obligatoriedad de las referencias bibliográficas) no se aplicaban al construirse con el patrón builder, lo que provocaba violaciones




Figura 4.3: Pull request desbloqueado tras la finalización exitosa del workflow. El check “Build and Verify Services” aparece como requerido y exitoso, habilitando la opción de merge.

de restricciones de nulidad en la base de datos cuando el cliente omitía dichos campos. En UAA, la actualización de las preferencias de correo de un usuario persistía un valor nulo al recibir una lista vacía. Finalmente, en PAIMA se encontraron dos defectos sutiles: la consulta de registros a Loki fallaba de forma silenciosa porque la expresión LogQL no se codificaba correctamente en la URL, de modo que la evidencia de logs nunca llegaba a enriquecer las alertas; y la URL del proveedor compatible con OpenAI podía construirse con una doble barra que invalidaba el endpoint. Estos hallazgos ilustran el valor de las pruebas de integración sobre una base de datos real: ninguno de estos defectos era observable mediante pruebas unitarias con dobles ni mediante la revisión estática del código.

Lecciones de Testcontainers. El uso de contenedores Docker para pruebas de integración presentó desafíos iniciales relacionados con el tiempo de arranque y la gestión de recursos. Los primeros tests tardaban más de treinta segundos en levantar el contenedor MySQL, lo que ralentizaba el ciclo de retroalimentación del desarrollador. Se optimizó este tiempo mediante el uso de imágenes base ligera (`mysql:8-debian`) y la configuración de un pool de contenedores reutilizables mediante la anotación `@Testcontainers(disabledWithoutDocker = true)`. Asimismo, se identificó que la ejecución paralela de tests sobre el mismo contenedor podía generar condiciones de carrera cuando dos tests modificaban la misma tabla simultáneamente. La solución consistió en aislar cada test mediante

@Transactional con rollback automático al finalizar, garantizando que cada test parte de un estado limpio sin depender del orden de ejecución.

Documentación de APIs. Como parte del pipeline de integración continua, cada microservicio expone su documentación interactiva mediante Swagger UI, generada automáticamente a partir de las anotaciones presentes en los controladores REST. Esta interfaz viva describe los endpoints disponibles, los esquemas de request/response y los códigos de estado posibles, eliminando la necesidad de mantener manuales separados. La validez de la documentación se verifica visualmente en cada despliegue, constituyendo una evidencia complementaria de que la interfaz REST del servicio está correctamente especificada y accesible. La Figura 4.4 muestra el resultado correspondiente.




Figura 4.4: Interfaz Swagger UI del servicio Site, mostrando los endpoints REST documentados automáticamente.

4.3. Pruebas End-to-End

Mientras que las pruebas de integración validan capas individuales del backend, las pruebas end-to-end recorren la aplicación completa simulando interacciones reales del usuario. Su objetivo es detectar fallos de coordinación entre la interfaz, los servicios distribuidos y los mecanismos de autenticación.

4.3.1. Selección de Herramienta y Diseño de Flujos

Para la validación del sistema desde la perspectiva del usuario final se evaluaron diversas herramientas de automatización de pruebas de interfaz. Herramientas consolidadas basadas en controladores externos (*WebDrivers*) como **Selenium** constituyen un estándar de la industria, pero suelen introducir inestabilidad (*flakiness*) y tiempos de ejecución prolongados debido a la sincronización entre el driver y el navegador.

Se seleccionó **Cypress** porque se ejecuta dentro del mismo ciclo de vida del navegador, eliminando la capa de intermediación del WebDriver. Esta característica produce tiempos de respuesta más predecibles y reduce la tasa de falsos negativos producidos por condiciones de carrera en la interfaz.

Los flujos automatizados cubren las siguientes funcionalidades:

1. **Autenticación:** Inicio de sesión con credenciales válidas, validación de la sesión persistida en la cookie `exchange_session`, redirección al dashboard principal.
2. **Navegación por sitios de asignatura:** Acceso a la lista de sitios, selección de un semestre activo, visualización de detalle de curso.
3. **Gestión de contenidos:** Creación de un objetivo de aprendizaje, adición de una referencia bibliográfica, eliminación de un tema de contenido.
4. **Visualización de alertas PAIMA:** Acceso al módulo de alertas, filtrado por prioridad, apertura de chat contextual.

Dado que la autenticación está externalizada en el servicio UAA, los tests realizan peticiones directas de inicio de sesión contra el endpoint `/v1/auth/login` para obtener el token JWT, que luego se inyecta en las cabeceras de las peticiones subsecuentes. Este mecanismo evita la complejidad de navegar múltiples dominios durante la prueba, acelerando la ejecución y reduciendo la fragilidad del suite. La Figura 4.5 muestra el resultado correspondiente.

4.3.2. Resultados de Ejecución

La suite completa de Cypress consta de doce *specs* que agrupan un total de cincuenta y dos casos de prueba. La ejecución sobre el entorno Docker Compose local tiene una duración promedio de un minuto y dieciséis segundos. De veinte ejecuciones consecutivas registradas, dieciocho finalizaron con el cien por ciento de los casos exitosos; las dos restantes presentaron una única falla en la utilidad de captura de pantalla del navegador (*timeout* de `cy.screenshot`), sin que fallara ninguna aserción funcional de la aplicación. No se registraron falsos negativos atribuibles a condiciones de carrera ni a tiempos de espera insuficientes, lo que valida la estabilidad del flujo de autenticación y la consistencia de la interfaz de usuario.

Evolución de la suite. La suite de Cypress no se construyó de forma estática: creció orgánicamente a medida que se identificaban flujos críticos del usuario. Las




Figura 4.5: Vista general del dashboard de Cypress, mostrando la cobertura de las funcionalidades de la aplicación a través de pruebas de automatización end-to-end.

primeras versiones contaban con seis *specs* que cubrían únicamente autenticación y navegación básica. A medida que se implementaron nuevas funcionalidades en el frontend —gestión de contenidos, filtrado de alertas, visualización de métricas— se agregaron *specs* correspondientes que verifican cada flujo de extremo a extremo. Esta evolución demuestra que la suite E2E no es un componente aislado del desarrollo, sino una extensión de la especificación funcional: cada nueva característica del sistema debe incluir su correspondiente prueba de interfaz antes de ser considerada completa.

Gestión de la autenticación externalizada. Un desafío particular del suite E2E fue el manejo de la autenticación distribuida entre el frontend Vue.js y el servicio UAA. El frontend persiste la sesión en la cookie `exchange_session` mediante la biblioteca `js-cookie`, de modo que los tests debían replicar el flujo de login sin depender de la interfaz visual de autenticación, que puede cambiar de forma independiente. La solución consistió en implementar un comando personalizado de Cypress que realiza la petición de login directamente contra UAA y establece la cookie `exchange_session` con el par de tokens, de modo que el frontend la reconozca al recargar la página. Este patrón desacopla los tests E2E de la implementación visual del login, reduciendo la fragilidad del suite ante cambios cosméticos en la interfaz de autenticación.

Depuración de inestabilidad. Durante las primeras ejecuciones contra el stack real se detectaron discrepancias entre las aserciones iniciales y el com-

portamiento efectivo de la aplicación: la página principal resultó ser pública (no redirige al *login*), el módulo de administración redirige a su submódulo por defecto y ciertas pestañas del sitio solo son visibles para roles específicos. Las aserciones se ajustaron para reflejar el comportamiento real verificado, en lugar de aumentar globalmente los tiempos de espera. El proceso también expuso un defecto real en los datos de prueba (evaluaciones sembradas con un tipo inexistente en el enumerado del backend, que provocaba errores HTTP 500 al abrir el detalle de un sitio), el cual fue corregido tanto en los datos como en el generador del *seed*.

4.3.3. Validación de la Arquitectura Frontend Adaptada

Las pruebas end-to-end verifican no solo la estabilidad de la interfaz, sino que cada cambio arquitectónico introducido en la adaptación del frontend (Sección 3.4) tiene una contraparte validable en el suite de Cypress. A continuación se documentan los cuatro ejes de validación: autenticación distribuida, router modular con guards, comunicación multi-servicio y store Vuex por dominio.

Autenticación OAuth2/JWT El test `auth/oauth2-flow.spec.js` replica el flujo completo de inicio de sesión en cinco pasos: (1) el usuario accede a `/ingresar`, (2) el frontend obtiene un token anónimo mediante `client_credentials` contra UAA, (3) el usuario ingresa credenciales y el frontend intercambia el token anónimo por uno de usuario con `refresh_token`, (4) el frontend almacena el par de tokens en cookies y redirige al `dashboard`, y (5) al expirar el token de acceso, el frontend solicita automáticamente un nuevo par mediante `POST /v1/auth/refresh-token` sin interrumpir la navegación. Cada paso se aserta visualmente (URL, estado del botón, mensaje de bienvenida) y a nivel de red (inspección de cabeceras `Authorization` y cookies `exchange_session`). La Figura 4.6 muestra el resultado correspondiente.

Flujos de Negocio Integrales Además de los ejes arquitectónicos, se validaron flujos de negocio completos que atraviesan múltiples módulos y microservicios:

- **Gestión de contenidos académicos:** Creación de objetivos de aprendizaje, adición de referencias bibliográficas y eliminación de temas. Cada operación valida que el frontend invoque el endpoint correcto de Site (`/v1/site/{code}/objectives`, `/v1/site/{code}/references`) y maneje los códigos de estado HTTP (201, 204, 404) con mensajes de error comprensibles para el usuario.
- **Operaciones administrativas:** Creación de asignaturas, inscripción de participantes y configuración de horarios. Estos flujos requieren permisos de `coordinator` o superior, por lo que los tests verifican que los guards del router (`requiresCoordOrBetter`, `requiresAdmin`) bloqueen el acceso directo a la URL para usuarios sin privilegios.




Figura 4.6: Secuencia de pasos del flujo de autenticación OAuth2/JWT validada mediante Cypress: obtención de token anónimo, login con credenciales, persistencia en cookies y refresco automático.

- **Gestión de alertas PAIMA:** Acceso al módulo de alertas, filtrado por prioridad, apertura del chat contextual y aprobación de acciones propuestas. El test valida que el frontend comunique correctamente con el servicio PAIMA (/paima/alerts) y que el asistente conversacional renderice la respuesta del modelo de IA sin bloquear la interfaz.

Resultados de estabilidad. La suite de Cypress se ejecutó veinte veces de forma consecutiva sobre el entorno Docker Compose completo, incluyendo el contenedor `frontend`. La duración promedio fue de un minuto y dieciséis segundos, con dieciocho ejecuciones completamente exitosas y dos con una falla aislada de la utilidad de captura del navegador. No se registraron falsos negativos atribuibles a condiciones de carrera, latencia de red entre contenedores ni cambios en la estructura de respuesta de los microservicios. Esta estabilidad demuestra que la adaptación del frontend —múltiples instancias Axios, router modular, guards de navegación y store Vuex por dominio— no introdujo fragilidad en la integración con el ecosistema distribuido.

Regresión visual. El *spec* de regresión visual captura *screenshots* de las vistas críticas (*login*, página principal, detalle de sitio, panel de alertas PAIMA) mediante el comando nativo `cy.screenshot` de Cypress, combinándolos con aserciones de visibilidad sobre los elementos estructurales de cada vista. Esta técnica complementa las aserciones funcionales con evidencia gráfica de la interfaz, protegiendo la experiencia de usuario ante modificaciones accidentales en los estilos o en la estructura del DOM.

4.4. Benchmarking de Rendimiento

Además de la corrección funcional, es necesario verificar que la nueva arquitectura responde adecuadamente ante tráfico concurrente. Esta sección documenta el experimento de benchmarking ejecutado para comparar latencia, throughput y tasa de error frente al sistema heredado, con ambas arquitecturas desplegadas localmente sobre el mismo hardware y con idéntica asignación de recursos.

4.4.1. Diseño del Experimento

Para cuantificar el rendimiento del nuevo ecosistema bajo carga representativa se diseñó un plan de benchmarking que evalúa tres escenarios críticos: consultas intensivas de lectura (GET), operaciones de creación (POST) y flujos de autenticación. Cada escenario se ejecutó durante cinco minutos utilizando **k6** [43] como herramienta de generación de carga, configurada con cincuenta usuarios virtuales concurrentes y una rampa de inicio progresivo de treinta segundos.

Configuración de los escenarios de carga. Los tres escenarios se implementan como scripts independientes de k6 escritos en JavaScript. Cada script realiza las siguientes operaciones:

GET intensivo: El script `benchmark-course-list.js` ejecuta peticiones GET `/v1/course` contra el servicio Site. En la fase `setup`, el script obtiene un token JWT válido mediante el flujo `client_credentials` contra el servicio UAA, inyectando el token en la cabecera `Authorization: Bearer <token>` de todas las iteraciones. Este escenario ejerce presión sobre la capa de persistencia de Site, que debe resolver la consulta con paginación sobre el catálogo de asignaturas.

POST de creación: El script `benchmark-course-create.js` ejecuta peticiones POST `/v1/course` con un *payload* JSON que incluye código de asignatura, nombre, nivel y carreras asociadas, con códigos sintéticos únicos derivados del identificador de usuario virtual y del contador de iteración para evitar colisiones de unicidad. El token JWT se obtiene de la misma forma que en el escenario anterior. Este escenario valida el rendimiento de escritura, la integridad de transacciones y la ejecución de validaciones de negocio sobre restricciones de unicidad.

Flujo de autenticación: El script `benchmark-auth-flow.js` ejecuta una secuencia de dos peticiones: primero POST `/v1/auth/login` con las credenciales de un usuario de prueba para obtener el token JWT, y seguidamente GET `/v1/user/{identity}` con dicho token en la cabecera de autorización. Este escenario mide la latencia del servicio UAA bajo carga concurrente de verificación de credenciales (*hashing* bcrypt) y resolución de identidad.

Monolito legacy. Los mismos tres escenarios se ejecutan sobre el monolito legacy utilizando los endpoints equivalentes: GET `/portapi/courses` (listado), POST `/portapi/courses` (creación) y POST `/portapi/sessions` seguido de GET `/portapi/users/me` (autenticación), con el mismo usuario de prueba y el mismo volumen de datos migrado. La carga se genera con la misma configuración de k6 para garantizar la comparabilidad de resultados.

Métricas recolectadas. Para cada escenario se registran las siguientes métricas: latencia media y percentil p95, throughput (peticiones por segundo), tasa de error (porcentaje de respuestas con código HTTP distinto de 2xx) y uso de CPU/memoria de los contenedores mediante Prometheus. Los resultados se comparan término a término entre ambas arquitecturas y se presentan en la subsección de resultados.

4.4.2. Análisis de Diseño Experimental

Los benchmarks de rendimiento constituyen la línea de validación cuantitativa del comportamiento del ecosistema bajo carga representativa. El diseño experimental descrito en esta sección establece los escenarios, las métricas y las hipótesis que orientaron la ejecución de las pruebas y la interpretación de las mediciones.

Hipótesis sobre latencia. Se espera que el monolito legacy exhiba mayor latencia percentil bajo carga concurrente porque concentra todas las peticiones en un único proceso Node.js con un único hilo de ejecución. Un cuello de botella en cualquier módulo —por ejemplo, el procesamiento de una consulta compleja sobre la tabla `site`— bloquea el *event loop* y retrasa todas las demás peticiones encoladas. En contraste, la arquitectura de microservicios distribuye la carga entre procesos independientes: el servicio UAA atiende autenticación, Site atiende consultas académicas y Notify atiende correos. Cada proceso opera con su propio pool de conexiones y su propia JVM, lo que debería traducirse en latencias más predecibles y menor variabilidad del percentil p99.

Hipótesis sobre throughput. El monolito, al carecer de mecanismos de caché distribuida y de pool de conexiones configurado para alta concurrencia, probablemente alcance un punto de saturación donde el throughput deja de crecer linealmente con la cantidad de usuarios concurrentes. La arquitectura de microservicios, con procesos especializados y bases de datos aisladas, debería exhibir un perfil de escalabilidad más lineal hasta el límite de recursos del hardware, siempre que no haya contención en recursos compartidos como la red interna de Docker.

Hipótesis sobre aislamiento de fallos. Bajo carga extrema, un error en el procesamiento de archivos adjuntos en el monolito podría comprometer la estabilidad de toda la aplicación, elevando la tasa de error global. En la arquitectura de microservicios, un fallo en el servicio Site afectaría únicamente ese dominio, mientras que los demás servicios continuarían respondiendo. Este aislamiento debería traducirse en una tasa de error global inferior y en una degradación gradual en lugar de una caída catastrófica.

Igualdad de condiciones del experimento. El benchmark se ejecutó con ambas arquitecturas desplegadas localmente sobre el mismo hardware, aplicando la misma política de recursos a los contenedores de cada stack —sin límites explícitos de CPU ni memoria en ninguno de los dos—, de modo que la comparación término a término se realiza en igualdad de recursos y las diferencias observadas son atribuibles a la arquitectura y no a disparidades de capacidad. Si bien un entorno local no reproduce todos los factores de un ambiente de producción

(caché del sistema operativo, cargas de fondo, condiciones de red), este factor es común a ambas mediciones y no compromete la validez de la comparación relativa. Cabe señalar que el ecosistema de microservicios introduce un overhead de red interna entre servicios, ausente en el monolito, factor que se considera en la interpretación de los resultados.

4.4.3. Resultados del Benchmarking

Escenario	Media (ms)	p95 (ms)	Throughput (req/s)	Error (%)
<i>Monolito legacy</i>				
GET intensivo	262,92	304,93	180,7	0,00
POST creación	90,40	117,01	526,8	1,39
Autenticación	37,22	79,97	1279,0	0,00
<i>Microservicios</i>				
GET intensivo	136,71	258,39	347,8	0,00
POST creación	85,86	119,00	553,9	0,00
Autenticación	168,86	246,20	282,2	0,00

Cuadro 4.3: *Resultados del benchmarking término a término entre el monolito legacy y el ecosistema de microservicios, bajo cincuenta usuarios virtuales durante cinco minutos por escenario*

La Tabla 4.3 consolida las métricas recolectadas para los tres escenarios en ambas arquitecturas y permite contrastar las hipótesis de latencia, throughput y aislamiento de fallos formuladas en la subsección anterior.

Lectura intensiva (GET). La hipótesis de latencia se confirma con claridad: el ecosistema de microservicios respondió con una latencia media de 136,71 ms frente a 262,92 ms del monolito (1,9 veces más rápido) y sostuvo un throughput de 347,8 peticiones por segundo frente a 180,7 (1,9 veces mayor), ambos con tasa de error nula. El monolito exhibe además una cola más pesada en el percentil p95 (304,93 ms frente a 258,39 ms), consistente con la saturación del *event loop* único de Node.js cuando las consultas se acumulan sobre un pool de conexiones reducido.

Escritura (POST). Ambas arquitecturas exhiben latencias estadísticamente equivalentes (85,86 ms frente a 90,40 ms de media; 119,00 ms frente a 117,01 ms en p95), lo que indica que la escritura transaccional está dominada por el costo de persistencia en la base de datos y no por la capa de aplicación. La diferencia relevante aparece en la robustez: el monolito respondió con error el 1,39 % de las peticiones, mientras que el servicio Site mantuvo una tasa de error nula. Las ejecuciones exploratorias mostraron, además, que ante violaciones de unicidad el monolito propaga la excepción de la base de datos como un error HTTP 500 genérico, mientras que el microservicio resuelve el conflicto de forma controlada e idempotente: una creación repetida con el mismo código se procesa como actualización exitosa (HTTP 200) sin generar registros duplicados.

Autenticación. Este es el único escenario donde el monolito exhibe mejores cifras brutas (37,22 ms de media y 1279,0 peticiones por segundo frente a 168,86 ms y 282,2). La diferencia no es arbitraria ni reversible sin costo: responde a una decisión deliberada de seguridad. El sistema heredado verifica las contraseñas con un *hash* MD5, computacionalmente trivial y considerado inseguro desde hace más de una década, mientras que el servicio UAA emplea **bcrypt** con un factor de trabajo que eleva deliberadamente el costo de cada verificación al rango de los cientos de milisegundos, además de la firma criptográfica del token JWT. El resultado cuantifica el precio de la seguridad: la verificación robusta de credenciales cuesta aproximadamente cinco veces más CPU por autenticación, un costo que la arquitectura absorbe aislándolo en un servicio especializado que puede escalar de forma independiente sin afectar los demás dominios.

Síntesis. En conjunto, los resultados respaldan las hipótesis de diseño: la arquitectura de microservicios mejora de forma significativa la lectura concurrente, iguala la escritura con mayor robustez ante errores y concentra en un servicio aislado el costo —deliberado— de la verificación segura de credenciales, todo ello sin una sola respuesta errónea atribuible a fallas de la plataforma en más de 390 mil peticiones ejecutadas contra el ecosistema. La Figura 4.7 muestra el panel de Grafana durante una de las corridas de carga sobre el servicio Site.




Figura 4.7: Panel de observabilidad de Grafana durante la ejecución del benchmark sobre el servicio Site: se aprecian el throughput sostenido de aproximadamente 300 peticiones por segundo, la latencia media del endpoint de lectura y la ausencia de respuestas de error (2xx al cien por ciento) bajo cincuenta usuarios virtuales

4.5. Simulación de Caos y Recuperación Asistida

La validación de resiliencia no puede limitarse a escenarios nominales. Es necesario someter el ecosistema a condiciones de fallo controladas para verificar que PAIMA detecte, diagnostique y asista en la recuperación de servicios caídos, limitando la intervención humana a la aprobación de la acción propuesta.

4.5.1. Diseño del Escenario

Para comprobar la resiliencia del ecosistema y el funcionamiento del modelo de auto-mantenimiento se diseñó un experimento de ingeniería del caos siguiendo la metodología descrita en el Marco Teórico [50]. El escenario consistió en detener de forma intencional el contenedor del servicio de sitios académicos (`ms-site`), emulando una caída catastrófica en un entorno de producción.

El protocolo de prueba estableció las siguientes fases:

1. **Estado basal:** Verificación de que todos los servicios están operativos, métricas dentro de rangos normales y sin alertas activas.
2. **Inyección de fallo:** Ejecución de `docker stop ms-site` seguida de una espera de cinco minutos para permitir que el scheduler de PAIMA complete al menos un ciclo completo de monitorización.
3. **Observación:** Registro del comportamiento del frontend, detección de métricas anómalas en Prometheus y consolidación de logs de error en Loki.
4. **Intervención:** Evaluación de la alerta generada por PAIMA, consulta al asistente de IA y aprobación de la acción de reinicio.
5. **Recuperación:** Verificación de que el servicio retorna al estado saludable y que las métricas se normalizan.

4.5.2. Comportamiento Observado

El experimento se ejecutó tres veces con resultados consistentes. El comportamiento registrado en cada iteración fue el siguiente:

1. **Detección y Aislamiento:** En su siguiente ciclo de monitorización, PAIMA detectó la caída del servicio a través del endpoint de salud de Prometheus y los errores de conexión reportados en los logs de Loki. El frontend, rediseñado de manera tolerante a fallos, absorbió el error de red y continuó operando de forma parcial, mostrando un indicador de degradación en lugar de bloquear la interfaz completa.
2. **Clasificación y Notificación:** PAIMA categorizó la eventualidad como incidente de máxima prioridad (P1) e invocó al servicio `ms-notify` para despachar un correo de advertencia con formato institucional. La alerta se persistió en la base de datos con estado “Pendiente de Acción”.
3. **Asistencia y Decisión Humana:** El administrador accedió al módulo de incidentes, visualizó la alerta con sus evidencias consolidadas (métricas de latencia, fragmentos de log y recomendación de la IA) y utilizó el chat contextual para solicitar una explicación detallada del diagnóstico antes de aprobar la acción de auto-reparación.

4. **Ejecución y Recuperación:** Tras la aprobación, PAIMA invocó `portaliasig-cli restart ms-site`, levantó el contenedor y verificó que el endpoint de salud respondiera con código HTTP 200. La alerta pasó a estado “Completada” y el frontend retomó la operación normal sin intervención manual adicional.

4.5.3. Interfaz de Operación del Sistema de Autogestión

El experimento de caos descrito en la sección anterior se opera a través de la interfaz de gestión de incidentes implementada en el frontend de PortalAsig. Esta interfaz, denominada “Alertas PAIMA”, se organiza en cuatro vistas que cubren el ciclo completo de atención de incidentes: un panel de control general, un listado de alertas por estado, una vista de detalle individual y un asistente conversacional. A continuación se presenta cada vista con la evidencia gráfica correspondiente.

Panel de control. La vista principal integra en una única pantalla el listado de alertas pendientes y gestionadas, el detalle contextual de la alerta seleccionada —con la recomendación del modelo de IA y la acción propuesta— y el acceso al asistente conversacional. Esta disposición permite al administrador evaluar la situación global del ecosistema y operar un incidente específico sin cambiar de vista. La Figura 4.8 muestra el panel durante la simulación de caos, con la alerta P1 del servicio Site en espera de aprobación.



Figura 4.8: Panel de control de PAIMA durante la simulación de caos, con la alerta P1 del servicio Site pendiente de aprobación.

Listado de alertas. Esta vista divide las incidencias en dos pestañas: “Pendientes de Acción” y “Completadas / Gestionadas”. Cada fila muestra la prioridad (P1, P2, P3), el servicio afectado, la descripción del síntoma detectado y la fecha de generación. Las incidencias se ordenan por severidad y se destacan con códigos de color (rojo para P1, amarillo para P2). La Figura 4.9 registra la alerta generada tras la caída del servicio Site.

Notificación por correo. Paralelamente a la visualización en el panel, PAIMA invoca al servicio `ms-notify` para despachar una alerta por correo




Figura 4.9: Listado de alertas autonómicas priorizadas visibles para el administrador.

electrónico con formato institucional. La Figura 4.10 muestra la notificación recibida por el administrador.

Detalle del incidente. Al seleccionar la alerta, el administrador accede a una vista que consolida toda la evidencia asociada: métricas de Prometheus en el momento del evento, fragmentos de log de Loki, la recomendación estructurada producida por el modelo de IA y los controles para aprobar, rechazar o comentar la acción propuesta. La Figura 4.11 ilustra la vista de detalle del incidente P1.

Asistente conversacional. Antes de ejecutar cualquier acción sobre la alerta, el administrador puede abrir un chat contextual para interrogar a la IA sobre la naturaleza del error, solicitar explicaciones adicionales o explorar pasos manuales alternativos. La Figura 4.12 muestra la interacción con el asistente durante el experimento.

Aprobación de la acción. Una vez revisada la evidencia y consultado el asistente, el administrador aprueba la acción de reinicio propuesta por PAIMA. La Figura 4.13 muestra el momento de aprobación y la ejecución de la auto-reparación.

Alerta en el portal administrativo. Tras la recuperación del servicio, el panel administrativo actualiza el estado de la alerta a “Completada” y el listado

CAPÍTULO 4. PRUEBAS Y RESULTADOS




Figura 4.10: Correo electrónico autogenerated por PAIMA al detectar la caída del servicio Site durante la simulación de caos, recibido por el administrador con el diagnóstico de la IA, la acción sugerida y el enlace al panel de alertas.




Figura 4.11: Vista de detalle de un incidente P1 en PAIMA, consolidando métricas, logs y recomendación de la IA.

refleja que la acción de reinicio aprobada restableció la operación normal. Este cambio de estado confirma que el ciclo MAPE-K cerró correctamente: detección, diagnóstico, propuesta, aprobación humana y ejecución de la remediación.




Figura 4.12: Interacción del administrador con el agente de IA para refinar el diagnóstico.

4.5.4. Lecciones del Experimento

La simulación de caos validó tres hipótesis fundamentales del trabajo. Primera: la arquitectura de microservicios aísla efectivamente los fallos, permitiendo que el frontend y los demás servicios continúen operativos aun cuando un nodo cae [9]. Segunda: el stack de observabilidad (Prometheus + Loki + Grafana) proporciona datos suficientes para que PAIMA detecte, clasifique y notifique incidentes sin intervención humana en las fases iniciales [30]. Tercera: la interfaz de gestión de incidentes reduce la carga cognitiva del administrador al consolidar toda la evidencia en un único punto y ofrecer un asistente conversacional que acelera la toma de decisiones.

No obstante, el experimento también reveló una limitación: el tiempo de detección depende directamente de la frecuencia del scheduler de PAIMA. Con un intervalo de cinco minutos entre ciclos, el servicio pudo permanecer caído hasta cuatro minutos y cincuenta y nueve segundos antes de que se generara la alerta. En un entorno de producción real, este umbral debería reducirse a treinta o sesenta segundos, ajustándose mediante el Config Server sin requerir modificación del código.




Figura 4.13: Aprobación y ejecución de la acción de auto-reparación mediante el asistente IA.

4.6. Análisis Comparativo Global

La Tabla 4.4 resume los hallazgos de las cuatro categorías de prueba, contrastando el estado del monolito legacy con el del ecosistema de microservicios.

Dimensión	Monolito Legacy	Ecosistema de Microservicios
Cobertura de código	Inexistente. Sin tests ni medición.	71 %–81 % de líneas por servicio, medido con JaCoCo y validado en pipeline.
Pruebas E2E	Manuales. Depende del navegador y del conocimiento tácito del tester.	Suite automatizada con doce <i>specs</i> y cuarenta y siete casos, con tasa de éxito del cien por ciento en veinte ejecuciones consecutivas.
Rendimiento bajo carga	Plan de benchmarking diseñado bajo idéntica configuración de carga para comparabilidad futura.	Plan de benchmarking con escenarios de lectura, escritura y autenticación; hipótesis de menor latencia y mayor aislamiento de carga.
Resiliencia ante fallos	Un error en cualquier módulo cae toda la aplicación.	Fallo aislado al servicio afectado. PAIMA detecta, notifica y asiste en la recuperación.
Observabilidad durante incidentes	Logs locales consultables con <code>pm2</code> . Diagnóstico manual y reactivo.	Métricas y logs centralizados. Diagnóstico asistido por IA con evidencia consolidada.

Cuadro 4.4: Resumen comparativo de resultados de pruebas: monolito vs. microservicios

Análisis por dimensión. En la dimensión de cobertura de código, la transformación es cualitativa: pasar de cero por ciento a superar el setenta por ciento de líneas en todos los servicios representa el establecimiento de una cultura de aseguramiento de calidad donde antes no existía ninguna. El umbral del setenta por ciento no es un número arbitrario: es el punto donde el código restante corresponde principalmente a configuraciones, mapeadores y clases de utilidad que no requieren lógica de negocio compleja, y donde alcanzar cobertura total implicaría tests de integración sobre componentes de infraestructura cuya validación aporta poco valor funcional.

En la dimensión de pruebas end-to-end, la suite de Cypress transforma la validación de un proceso manual, dependiente del conocimiento tácito del tester, en un mecanismo reproducible que cualquier colaborador puede ejecutar con un único comando. La tasa de éxito del cien por ciento en veinte ejecuciones consecutivas no garantiza la ausencia de errores, pero demuestra que los flujos críticos del sistema —autenticación, navegación, gestión de contenidos— son estables y que la interfaz de usuario responde de forma predecible ante las interacciones programadas.

En la dimensión de rendimiento, el experimento de benchmarking comparó ambas arquitecturas bajo cargas sintéticas equivalentes, desplegadas localmente sobre el mismo hardware con idéntica asignación de recursos, lo que garantiza que las diferencias observadas son atribuibles a la arquitectura y no a disparidades de capacidad. Las hipótesis formuladas —menor latencia en microservicios debido a la especialización de procesos, mayor aislamiento de carga entre dominios, y degradación gradual en lugar de caída catastrófica— se contrastan con las mediciones empíricas presentadas en la Sección 4.4.

En la dimensión de resiliencia, la simulación de caos demostró empíricamente que el ecosistema aísla fallos y que PAIMA detecta, clasifica y notifica incidentes sin intervención humana en las fases iniciales. Esta capacidad no existía en el monolito, donde un error en cualquier módulo podía comprometer la totalidad de la aplicación sin mecanismo de recuperación automatizado.

En conjunto, estos resultados evidencian que el ecosistema de microservicios no solo supera al monolito en capacidades de testing, observabilidad y resiliencia, sino que además proporciona métricas objetivas que permiten tomar decisiones informadas sobre la salud del sistema. La existencia de un pipeline automatizado, de reportes de cobertura y de un ciclo de autogestión del mantenimiento transforma la operación de un proceso artesanal y dependiente del conocimiento tácito en uno sistemático, medible y reproducible.

Más allá de la mejora técnica cuantificable, los resultados de este capítulo materializan las tres tendencias convergentes de la Web 3.0 definidas en el Marco Teórico: distribución arquitectónica, observabilidad instrumentada y análisis asistido por inteligencia artificial. La validación empírica documentada demuestra que la transición hacia una arquitectura distribuida, observable y autogestionada no es una proyección teórica, sino una transformación operativa concreta que habilita la evolución del sistema hacia las exigencias del nuevo paradigma.

Capítulo 5

Conclusiones y Recomendaciones

5.1. Conclusiones

El presente trabajo documentó la migración del backend monolítico de PortalAsig hacia una arquitectura de microservicios, la implementación de técnicas sistemáticas de mantenimiento de software sobre el nuevo ecosistema, y el diseño e implementación del servicio PAIMA como mecanismo de autogestión del mantenimiento asistido por inteligencia artificial. El hilo conductor que atraviesa los capítulos anteriores puede sintetizarse en tres transformaciones interdependientes: una transformación arquitectónica que desacopla el sistema en dominios independientes, una transformación metodológica que introduce validación automatizada en cada cambio de código, y una transformación operativa que delega el diagnóstico y la remediación de incidentes a un ciclo de control autónomo.

En la dimensión arquitectónica, se demostró que el monolito legacy de PortalAsig acumulaba seis años de deuda técnica en un único proceso Node.js donde un controlador de 3.629 líneas gestionaba dieciocho dominios de negocio distintos, sin mecanismo de aislamiento de fallos ni pruebas automatizadas. La migración a microservicios descompuso el backend en tres dominios acotados—UAA, Site y Notify— cada uno con su propia base de datos MySQL, su esquema de versionado independiente mediante Flyway y su ciclo de despliegue autónomo. Sobre este ecosistema se integró el servicio PAIMA como mecanismo de autogestión del mantenimiento. La Tabla 3.1 del Capítulo 3 evidenció que esta descomposición eliminó el acoplamiento referencial entre dominios del modelo monolítico y habilitó el aislamiento de fallos, de modo que la caída de un servicio ya no compromete la estabilidad del ecosistema completo.

En la dimensión de mantenimiento, se implementó un pipeline de integración continua mediante GitHub Actions que ejecuta análisis estático con Checkstyle, pruebas de integración sobre bases de datos reales con Testcontainers, y medición de cobertura con JaCoCo en cada *pull request*. Las reglas de protección de ramas

bloquean la fusión de código si cualquiera de estos checks falla, transformando la validación de un proceso manual y dependiente del conocimiento tácito en un mecanismo sistemático y reproducible. Los resultados documentados en el Capítulo 4 muestran coberturas de líneas entre el 71 % y el 81 % por microservicio, con umbrales mínimos del 70 % de líneas y 60 % de ramas validados automáticamente en cada pull request; cifras inexistentes en el monolito original. Asimismo, se diseñó una suite de pruebas end-to-end con Cypress que simula flujos completos de usuario sobre el frontend Vue.js, verificando que las capas de presentación, aplicación y persistencia operen de forma coordinada.

En la dimensión de autogestión, se implementó el servicio PAIMA como un caso de uso directo de la observabilidad distribuida instalada para monitorear los microservicios. PAIMA ejecuta un ciclo MAPE-K donde las fases de Análisis y Planificación se delegan a un modelo de lenguaje de gran escala, configurado como proveedor configurable con fallback determinista. Esta decisión se alinea con la dirección de investigación que integra MAPE-K con inteligencia artificial para la gestión autónoma de microservicios [3]. La simulación de caos documentada en el Capítulo 4 validó que PAIMA detecta la caída de un servicio, clasifica la incidencia con prioridad P1, notifica al administrador vía correo electrónico, consolida métricas y logs en un panel de gestión, y propone una acción de reinicio que el operador humano evalúa y aprueba mediante un asistente conversacional. Este flujo reduce la carga cognitiva del mantenedor y acelera la recuperación sin requerir intervención manual en las fases de detección y diagnóstico.

La contribución original de este trabajo reside en haber implementado de forma práctica el framework de [3] en un contexto académico con recursos limitados, donde no existe equipo de operaciones dedicado ni infraestructura cloud. PAIMA no es una arquitectura abstracta: sus conectores de monitoreo apuntan a instancias concretas de Prometheus y Loki desplegadas junto a los microservicios, y sus acciones de remediación invocan contenedores gestionados por Docker Compose. Esta materialización demuestra que la convergencia de distribución arquitectónica, observabilidad instrumentada e inteligencia artificial —las propiedades definidas en el Marco Teórico como tendencias convergentes de la Web 3.0— no es una proyección teórica, sino una transformación operativa alcanzable en entornos con restricciones de personal y presupuesto.

5.2. Limitaciones

Las principales limitaciones del trabajo se concentran en los bordes operativos del ecosistema validado. En primer lugar, la frecuencia del ciclo de monitoreo de PAIMA —cinco minutos en la configuración empleada— acota el tiempo de detección de una incidencia: un servicio puede permanecer caído durante casi un ciclo completo antes de que se genere la alerta, un intervalo reducible mediante el Config Server pero inherentemente ligado a la naturaleza periódica del ciclo. En segundo lugar, la calidad del diagnóstico en las fases de Análisis y Planificación depende del proveedor de inteligencia artificial configurado: los proveedores remotos ofrecen mayor capacidad de razonamiento, pero introducen

una dependencia de la conectividad externa y costos recurrentes de consumo de APIs de terceros que escalan con el volumen de tokens procesados, mientras que el proveedor local y el fallback determinista basado en reglas garantizan la continuidad operativa con diagnósticos menos detallados. En tercer lugar, la evaluación cuantitativa de rendimiento se realizó sobre instancias locales de ambas arquitecturas, desplegadas en el mismo ambiente de pruebas con asignación idéntica de recursos de CPU y memoria, lo que garantizó una comparación término a término en igualdad de condiciones; no obstante, los resultados corresponden a un entorno controlado con datos anonimizados, por lo que sus magnitudes absolutas no necesariamente se reproducen en un entorno de producción. Finalmente, el frontend heredado opera sobre Vue.js 2, versión que alcanzó su fin de vida, y la validación del ecosistema se realizó sobre el entorno local de Docker Compose con datos anonimizados; la migración de los datos históricos de producción y la instrumentación de trazabilidad distribuida quedaron fuera del alcance de este trabajo.

5.3. Recomendaciones y Trabajo Futuro

A partir de los resultados obtenidos y las limitaciones observadas durante el desarrollo y la validación, se identifican las siguientes líneas de evolución para el ecosistema PortalAsig.

Soberanía tecnológica mediante modelos locales. Si bien la arquitectura de PAIMA incorpora un proveedor basado en Ollama para la ejecución de modelos locales, la validación de este trabajo se realizó con proveedores de inteligencia artificial remotos (APIs compatibles con OpenAI) por su mayor capacidad de razonamiento. Como línea de evolución, se recomienda la evaluación sistemática de modelos de lenguaje ejecutados localmente, ajustando los *prompts* sobre el historial de incidentes acumulado y midiendo la calidad del razonamiento frente a los proveedores remotos actuales. Esta transición eliminaría la dependencia de conectividad externa y de costos por token, al tiempo que preservaría la confidencialidad de la telemetría operativa dentro de la infraestructura universitaria.

Centralización del routing y la autenticación. Se recomienda evaluar la introducción de un gateway —ya sea una extensión de Nginx o un componente dedicado como Spring Cloud Gateway— para simplificar la seguridad perimetral y reducir la complejidad de configuración de CORS en cada microservicio.

Evolución de PAIMA hacia un agente semi-integrado de desarrollo. En su configuración actual, PAIMA opera como un agente de operaciones que monitorea métricas y logs del ecosistema en ejecución. Como línea de evolución, se propone extender su alcance hacia el código fuente mismo, transformándolo en un agente semi-integrado que asista al mantenedor en tareas de ingeniería de software más amplia. Esta evolución contemplaría tres capacidades adicionales.

En primer lugar, la integración con los repositorios de código alojados en GitHub mediante la API oficial del servicio. PAIMA podría leer el historial de *commits*, analizar *pull requests* abiertos, inspeccionar reportes de issues y

correlacionar alertas operativas con cambios recientes en el código. Por ejemplo, un pico de latencia en el servicio Site podría asociarse automáticamente con un *merge* reciente que modificó la capa de persistencia, reduciendo el tiempo de diagnóstico desde minutos a segundos.

En segundo lugar, el análisis estático del código fuente combinado con el conocimiento operativo ya acumulado en la base de datos de PAIMA. Mediante la lectura periódica de los repositorios, el agente podría identificar *code smells*, deuda técnica acumulada, inconsistencias en convenciones de nomenclatura y oportunidades de refactorización que escapan a las reglas rígidas de Checkstyle. Esta capacidad trasciende la detección de errores: permite realizar *discovery & improve* sobre el repositorio, sugiriendo extracciones de métodos, simplificaciones de clases complejas o eliminación de dependencias circularizadas que degradan la mantenibilidad del sistema.

En tercer lugar, una interfaz conversacional extendida que permita al administrador no solo consultar sobre incidentes activos, sino también solicitar acciones de mejora continua y asistencia en el desarrollo de nuevas funcionalidades. El administrador podría formular consultas del tipo “¿qué servicio presenta mayor deuda técnica este mes?”, “genera un resumen de los *commits* relacionados con la caída de ayer” o “propón una implementación para el endpoint de importación masiva de semestres que está pendiente”. El agente respondería generando fragmentos de código, diagramas de secuencia o planes de implementación basados en el conocimiento del dominio y del código existente, manteniendo un ciclo de aprobación humana antes de cualquier modificación efectiva.

Esta visión de PAIMA como agente semi-integrado —semi porque opera con supervisión humana, integrado porque conecta operaciones, código y desarrollo en un único ciclo de retroalimentación— representa un paso hacia la autogestión del mantenimiento en su acepción más completa. No se trata de sustituir al ingeniero de software, sino de reducir la fricción entre la observación del sistema, la comprensión de su código y la ejecución de mejoras, especialmente crítico en un contexto donde los colaboradores académicos temporales deben asumir tareas de operación y desarrollo simultáneamente.

Modelos de lenguaje especializados con habilidades operativas. Más allá del análisis y la recomendación, se propone investigar el entrenamiento de un modelo de lenguaje de pequeña escala (SLM, *Small Language Model*) sobre el dominio académico de PortalAsig, combinado con un sistema de *skills* o herramientas invocables. El objetivo es que el agente no solo converse con el administrador, sino que ejecute directamente operaciones de negocio sobre los microservicios mediante llamadas a sus APIs REST.

Esta arquitectura requeriría definir un catálogo de habilidades estructuradas que cubran las operaciones más frecuentes del sistema: creación de sitios académicos, alta de asignaturas, inscripción masiva de estudiantes mediante archivos CSV, generación de períodos semestrales, configuración de evaluaciones con pesos, y envío de notificaciones institucionales. Cada habilidad se implementaría como una función con esquema de entrada validado (nombre del curso, código, período académico, lista de correos), que el modelo invoca una vez que ha interpretado la intención del usuario a partir de un prompt en lenguaje natural. Por

ejemplo, la orden “abre el sitio de Cálculo I para el semestre 2025-1 e inscribe a los estudiantes del listado adjunto” se traduciría en una secuencia de tres llamadas API —creación del sitio, vinculación de la asignatura, carga masiva de participantes— ejecutadas de forma atómica y supervisada.

Para garantizar la seguridad y la trazabilidad, cada invocación de habilidad debería someterse a un ciclo de confirmación humana: el agente presentaría un resumen de las acciones propuestas, los datos afectados y las APIs involucradas, permitiendo al administrador aprobar, modificar o cancelar la operación antes de su ejecución. Este patrón mantiene el principio de autogestión asistida que caracteriza a PAIMA: la inteligencia artificial reduce la carga cognitiva y elimina la necesidad de conocer los endpoints técnicos, pero la autoridad final reside en el operador humano.

El impacto de esta evolución trasciende la comodidad del administrador. En el contexto operativo de PortalAsig, donde los colaboradores académicos temporales deben alternar entre desarrollo de nuevas funcionalidades y operación del sistema en producción, una interfaz conversacional que permita gestionar el dominio académico sin escribir código ni recordar rutas de API desacopla la operación del conocimiento técnico profundo. Un coordinador de asignatura con permisos administrativos podría crear sitios, configurar evaluaciones y enviar notificaciones sin intervención de un ingeniero de software, acelerando los ciclos administrativos del semestre y reduciendo los cuellos de botella que actualmente dependen de la disponibilidad del mantenedor.

Evolución hacia una arquitectura multi-agente distribuida. PAIMA implementa actualmente un ciclo MAPE-K centralizado: un único agente monitorea el ecosistema completo y ejecuta acciones de remediación. Como trabajo futuro de investigación, se propone explorar la evolución hacia una arquitectura tipo AWARE, donde múltiples agentes de inteligencia artificial colaboran entre nodos del ecosistema de forma distribuida [54]. Esta transición representaría un salto desde la autogestión asistida centralizada hacia una computación autónoma plena, donde cada microservicio podría incorporar capacidades de auto-diagnóstico y auto-remediación local, coordinándose con los demás mediante protocolos de consenso multi-agente.

Migración del frontend a Vue.js 3. El frontend actual opera sobre Vue.js 2, versión que alcanzó fin de vida a finales de 2023 y no recibe actualizaciones de seguridad ni correcciones. Como línea de trabajo futuro, se recomienda la migración a Vue.js 3, que introduce la Composition API, una reactividad más eficiente basada en Proxies, mejoras de rendimiento en el renderizado y compatibilidad con herramientas modernas como Vite. Esta migración requeriría actualizar las dependencias principales (Vuex a Pinia o Vue 3 Composition API, Vue Router 4, adaptación de componentes de Bootstrap-Vue) y reescribir los componentes de clase a la sintaxis de `script setup`, pero preservaría la arquitectura modular y los flujos de autenticación ya establecidos.

Cobertura de código y pruebas de integración en el frontend. El backend cuenta con medición sistemática de cobertura mediante JaCoCo, umbral de aceptación en pipeline y pruebas de integración sobre bases de datos reales. El frontend, por su parte, carece de un equivalente: no se instrumenta cobertura

de código JavaScript ni se ejecutan pruebas de integración de componentes Vue.js como parte del proceso de validación. Como línea de trabajo futuro, se recomienda incorporar Istanbul/nyc para medir la cobertura de código del frontend, establecer un umbral mínimo en GitHub Actions y complementar las pruebas end-to-end de Cypress con pruebas de integración de componentes mediante Vue Test Utils y Jest. Esta práctica cerraría la brecha de calidad entre la capa de presentación y la capa de aplicación, garantizando que los refactors del store Vuex, los guards del router y los formularios reactivos conserven su comportamiento ante modificaciones.

Alcance explícito fuera del trabajo. Es importante precisar que el presente trabajo se centra en la integración continua (CI) como técnica de aseguramiento de calidad. La entrega continua (CD, *Continuous Delivery*), que automatiza el despliegue de artefactos validados hacia entornos de producción, queda fuera del alcance documentado. La implementación de pipelines de CD requeriría infraestructura adicional de despliegue automatizado sobre los servidores universitarios, lo cual constituye un proyecto independiente de significativa complejidad operativa.

Glosario

- Appender** Componente de un framework de *logging* que define el destino de los registros (consola, archivo, servidor remoto, etc.).
- Bean** En el contexto de Spring, objeto gestionado por el contenedor de inversión de control, cuyo ciclo de vida y dependencias son administrados por el framework.
- Bearer token** Tipo de token de seguridad que otorga acceso a quien lo posee, transmitido en la cabecera **Authorization** de las peticiones HTTP.
- Bill of Materials (BOM)** En Maven, mecanismo que centraliza y alinea las versiones de un conjunto de dependencias relacionadas.
- Client credentials** Flujo de autorización OAuth2 donde una aplicación se autentica directamente con sus credenciales, sin intervención de un usuario final.
- CORS (Cross-Origin Resource Sharing)** Mecanismo de seguridad que permite a un servidor web restringir los recursos que pueden solicitarse desde un dominio diferente al suyo.
- H2** Motor de base de datos relacional ligero que se ejecuta en memoria dentro del mismo proceso de la aplicación, utilizado frecuentemente en pruebas unitarias por su rapidez de arranque, pero que no reproduce las características de un motor de producción como MySQL.
- LTS (Long Term Support)** Versión de software que recibe actualizaciones de seguridad y correcciones durante un período extendido, típicamente varios años.
- Mock** Objeto simulado que imita el comportamiento de un componente real en un entorno controlado, utilizado para aislar la unidad bajo prueba.
- NoSQL (Not Only SQL)** Categoría de bases de datos que no emplean el modelo relacional tradicional, ofreciendo esquemas flexibles y escalabilidad horizontal.

- On-premise** Modalidad de despliegue donde la infraestructura de software reside en instalaciones propias de la organización, en contraste con modelos de computación en la nube.
- Payload** Carga útil de datos transportada dentro de un mensaje o petición, excluyendo las cabeceras de protocolo.
- PM2** Gestor de procesos para Node.js que permite mantener aplicaciones activas, recargarlas sin detener el servicio y monitorear su consumo de recursos.
- POM (Project Object Model)** Archivo descriptor XML en Maven que define la configuración, dependencias y ciclo de vida de un proyecto Java.
- Prompt** Instrucción de texto que se proporciona a un modelo de inteligencia artificial para guiar su respuesta o comportamiento.
- Proxy inverso** Servidor intermedio que recibe peticiones de clientes externos y las redirige hacia uno o múltiples servidores backend, ocultando la topología interna del ecosistema.
- Scheduler** Componente que programa y ejecuta tareas de forma periódica o programada en el tiempo.
- Snapshot** Captura instantánea del estado de un sistema en un momento determinado, utilizada para análisis posterior o restauración.
- Spec (especificación)** En el contexto de Cypress, archivo que agrupa un conjunto de casos de prueba relacionados con una funcionalidad particular.
- Refresh token** Token de larga duración emitido junto al *access token* en flujos OAuth2. Permite obtener un nuevo par de tokens de acceso cuando el original expire, sin solicitar nuevamente las credenciales del usuario.
- Branch protection** Regla de configuración en plataformas de control de versiones (como GitHub) que bloquea la fusión directa de código en la rama principal, exigiendo revisión humana y validación automatizada antes de aceptar cambios.
- Pull request** Solicitud formal para fusionar cambios de una rama secundaria hacia la rama principal de un repositorio. Incluye revisión de código, discusión y ejecución de pipelines de validación antes de la aprobación.
- Endpoint** URL específica de un servicio web que expone una operación determinada (consulta, creación, actualización o eliminación) y responde mediante un protocolo HTTP.
- Build** Proceso de compilación, empaquetado y validación de un proyecto de software a partir de su código fuente. Incluye la ejecución de análisis estáticos y pruebas automatizadas.

Boilerplate Código repetitivo y mecánico que debe escribirse en múltiples partes de un proyecto, típicamente automatizado mediante herramientas como Lombok o generadores de código.

DTO (Data Transfer Object) Objeto de transferencia de datos: estructura ligera utilizada para transportar información entre capas de una aplicación (por ejemplo, desde el backend hacia el frontend) sin exponer directamente las entidades de persistencia.

Pipeline Secuencia automatizada de pasos en un proceso de integración continua: compilación, análisis de estilo, ejecución de pruebas y generación de reportes, disparada automáticamente ante cambios en el repositorio.

Dashboard Panel visual que centraliza métricas, gráficos e indicadores de un sistema en un único punto de consulta, facilitando el monitoreo y diagnóstico del estado operativo.

Throughput Métrica de rendimiento que indica la cantidad de peticiones o transacciones que un sistema puede procesar por unidad de tiempo (típicamente por segundo).

JVM (Java Virtual Machine) Máquina virtual de Java: entorno de ejecución que interpreta el *bytecode* compilado de programas Java, proporcionando portabilidad entre sistemas operativos y gestión automática de memoria.

Seeding Carga automatizada de datos de prueba en una base de datos para reproducir un estado conocido del sistema antes de ejecutar pruebas o demostraciones.

SPA (Single Page Application) Aplicación de página única: tipo de interfaz web que carga una sola página HTML y actualiza dinámicamente su contenido mediante JavaScript, sin recargar completamente el navegador en cada navegación.

Scraping Modelo de recolección de métricas en el que un agente central consulta periódicamente los endpoints expuestos por los servicios monitoreados, como el empleado por Prometheus.

MAPE-K Ciclo de control de la computación autónoma propuesto por IBM, organizado en las fases de Monitoreo, Análisis, Planificación y Ejecución, apoyadas sobre una base de Conocimiento compartida.

Referencias

- [1] R. A. Vásquez Balza, “Implementación de una metodología de mantenimiento de software para la solución y prevención de fallas del sistema portalesig2,” 2020. Trabajo Especial de Grado, Universidad Central de Venezuela.
- [2] R. E. S. Santos, “Uses, benefits, and limitations of job rotation in software engineering,” *ACM SIGSOFT Software Engineering Notes*, vol. 41, no. 6, pp. 1–4, 2016. [Online]. Available: <https://dl.acm.org/doi/pdf/10.1145/3011286.3011300>.
- [3] M. Esposito, A. Bakhtin, N. Ahmad, M. Robredo, R. Su, V. Lenarduzzi, and D. Taibi, “Autonomic microservice management via agentic AI and MAPE-K integration,” *arXiv preprint arXiv:2506.22185*, 2025. [Online]. Available: <https://arxiv.org/abs/2506.22185>.
- [4] T. O’Reilly, “What Is Web 2.0: Design Patterns and Business Models for the Next Generation of Software.” O’Reilly Media, 2005. [Online]. Available: <https://www.oreilly.com/pub/a/web2/archive/what-is-web-20.html>.
- [5] T. Berners-Lee, J. Hendler, and O. Lassila, “The semantic web,” *Scientific American*, vol. 284, no. 5, pp. 34–43, 2001.
- [6] G. Edelman, “What is web3, anyway?,” *Wired*, 2021. Interview with Gavin Wood, who coined the term Web 3.0 in a blockchain context in 2014. [Online]. Available: <https://www.wired.com/story/web3-gavin-wood-interview/>.
- [7] M. Shen, Z. Tan, D. Niyato, Y. Liu, J. Kang, Z. Xiong, L. Zhu, W. Wang, and S. Xuemin, “Artificial intelligence for web 3.0: A comprehensive survey,” *arXiv preprint arXiv:2309.09972*, 2023. [Online]. Available: <https://arxiv.org/abs/2309.09972>.
- [8] Z. Kuai, G. Huang, X. Tao, G. Pasi, L. Yao, C. Liu, and N. Zhong, “Web intelligence (WI) 3.0: In search of a better-connected world to create a future intelligent society,” *Artificial Intelligence Review*, 2025.
- [9] C. Richardson, *Microservices patterns: with examples in Java*. Simon and Schuster, 2018.

- [10] B. Foote and J. Yoder, “Big ball of mud,” in *Pattern Languages of Program Design 4*, pp. 654–692, Addison-Wesley, 1997.
- [11] M. Fowler and J. Lewis, “Microservices: a definition of this new architectural term,” *Martin Fowler*, vol. 14, 2014. [Online]. Available: <https://martinfowler.com/articles/microservices.html>.
- [12] E. Evans, *Domain-Driven Design: Tackling Complexity in the Heart of Software*. Addison-Wesley, 2003.
- [13] Docker Inc., “Docker documentation.” <https://docs.docker.com/>, 2024. Accessed: 2026-08-27.
- [14] D. Inc., “Docker compose documentation.” <https://docs.docker.com/compose/>, 2024. Accessed: 2026-05-21.
- [15] OpenJS Foundation, “Express.js.” <https://expressjs.com/>, 2024. Accessed: 2026-08-27.
- [16] VMware, Inc., “Spring boot.” <https://spring.io/projects/spring-boot>, 2024. Accessed: 2026-08-27.
- [17] VMware, Inc., “Spring cloud.” <https://spring.io/projects/spring-cloud>, 2024. Accessed: 2026-08-27.
- [18] The Apache Software Foundation, “Apache maven documentation.” <https://maven.apache.org/guides/>, 2024. Accessed: 2026-08-27.
- [19] Project Lombok, “Project lombok.” <https://projectlombok.org/features/>, 2024. Accessed: 2026-08-27.
- [20] MapStruct, “Mapstruct reference guide.” <https://mapstruct.org/documentation/stable/reference/html/>, 2024. Accessed: 2026-08-27.
- [21] M. Jones, J. Bradley, and N. Sakimura, “Json web token (JWT).” RFC 7519, IETF, 2015. [Online]. Available: <https://tools.ietf.org/html/rfc7519>.
- [22] D. Hardt, “The oauth 2.0 authorization framework.” RFC 6749, IETF, 2012. [Online]. Available: <https://tools.ietf.org/html/rfc6749>.
- [23] F5, Inc., “nginx documentation.” <https://nginx.org/en/docs/>, 2024. Accessed: 2026-08-27.
- [24] The Apache Software Foundation, “Apache kafka documentation.” <https://kafka.apache.org/documentation/>, 2024. Accessed: 2026-08-27.
- [25] Eclipse Foundation, “Jakarta persistence.” <https://jakarta.ee/specifications/persistence/>, 2024. Accessed: 2026-08-27.
- [26] Hibernate, “Hibernate orm documentation.” <https://hibernate.org/orm/documentation/>, 2024. Accessed: 2026-08-27.

- [27] R. Gate, “Flyway documentation.” <https://documentation.red-gate.com/flyway>, 2024. Accessed: 2026-05-21.
- [28] Oracle Corporation, “Mysql documentation.” <https://dev.mysql.com/doc/>, 2024. Accessed: 2026-08-27.
- [29] The PostgreSQL Global Development Group, “Postgresql documentation.” <https://www.postgresql.org/docs/>, 2024. Accessed: 2026-08-27.
- [30] C. Sridharan, *Distributed Systems Observability*. O’Reilly Media, Inc., 2018.
- [31] P. Authors, “Prometheus documentation.” <https://prometheus.io/docs/introduction/overview/>, 2024. Accessed: 2026-05-21.
- [32] G. Labs, “Grafana documentation.” <https://grafana.com/docs/>, 2024. Accessed: 2026-05-21.
- [33] Checkstyle, “Checkstyle.” <https://checkstyle.org/>, 2024. Accessed: 2026-08-27.
- [34] Eclemma, “Jacoco java code coverage library.” <https://www.jacoco.org/jacoco/trunk/doc/>, 2024. Accessed: 2026-08-27.
- [35] AtomicJar, “Testcontainers.” <https://testcontainers.com/>, 2024. Accessed: 2026-05-21.
- [36] Selenium Project, “Selenium documentation.” <https://www.selenium.dev/documentation/>, 2024. Accessed: 2026-08-27.
- [37] Microsoft, “Playwright documentation.” <https://playwright.dev/docs/intro>, 2024. Accessed: 2026-08-27.
- [38] OpenJS Foundation, “Eslint documentation.” <https://eslint.org/docs/latest/>, 2024. Accessed: 2026-08-27.
- [39] Prettier, “Prettier documentation.” <https://prettier.io/docs/en/>, 2024. Accessed: 2026-08-27.
- [40] Cypress.io, “Cypress documentation.” <https://docs.cypress.io/>, 2024. Accessed: 2026-05-21.
- [41] Jenkins Project, “Jenkins user documentation.” <https://www.jenkins.io/doc/>, 2024. Accessed: 2026-08-27.
- [42] GitHub Inc., “Github actions documentation.” <https://docs.github.com/en/actions>, 2024. Accessed: 2026-08-27.
- [43] Grafana Labs, “Grafana k6 documentation.” <https://grafana.com/docs/k6/latest/>, 2024. Accessed: 2026-08-27.
- [44] OpenAPI Initiative, “Openapi specification.” <https://spec.openapis.org/oas/latest.html>, 2024. Accessed: 2026-08-27.

- [45] Vue.js, “Vue.js guide.” <https://vuejs.org/guide/introduction.html>, 2024. Accessed: 2026-05-21.
- [46] Axios, “Axios documentation.” <https://axios-http.com/docs/intro>, 2024. Accessed: 2026-08-27.
- [47] BootstrapVue, “Bootstrapvue documentation.” <https://bootstrap-vue.org/>, 2024. Accessed: 2026-08-27.
- [48] Ollama, “Ollama.” <https://github.com/ollama/ollama>, 2024. Accessed: 2026-08-27.
- [49] IEEE, “Iso/iec/ieee international standard for software engineering – software life cycle processes – maintenance,” 2006.
- [50] A. Basiri, N. Behnam, R. de Rooij, L. Hochstein, L. Kosewski, J. Reynolds, and C. Rosenthal, “Chaos engineering,” *IEEE Software*, vol. 33, no. 3, pp. 35–41, 2016.
- [51] J. O. Kephart and D. M. Chess, “The vision of autonomic computing,” *Computer*, vol. 36, no. 1, pp. 41–50, 2003.
- [52] N. C. Mendonça *et al.*, “An architecture for autonomic control of software systems,” *Journal of Systems and Software*, vol. 85, no. 12, pp. 2794–2811, 2012.
- [53] IBM, “An architectural blueprint for autonomic computing,” *IBM White Paper*, 2006. [Online]. Available: <https://users.cs.fiu.edu/~sadjadi/Teaching/Autonomic%20Grid%20Computing/CIS-6612-Summer-2006/AC-Blueprint-WhitePaper-V7.pdf>.
- [54] B. P. Sanwouo, C. Quinton, and P. Temple, “Breaking the loop: AWARE is the new MAPE-K,” in *Companion Proceedings of the 33rd ACM International Conference on the Foundations of Software Engineering (FSE Companion ’25)*, (Trondheim, Norway), pp. 626–630, ACM, 2025.
- [55] D. Weyns *et al.*, *Software Engineering for Self-Adaptive Systems*, vol. 7475 of *Lecture Notes in Computer Science*. Springer Berlin Heidelberg, 2013.
- [56] P. Notaro *et al.*, “A survey of aiops methods for failure management,” *ACM Transactions on Software Engineering and Methodology (TOSEM)*, vol. 30, no. 4, pp. 1–45, 2021. [Online]. Available: <https://dl.acm.org/doi/10.1145/3483424>.
- [57] Gartner, “Aiops (artificial intelligence for it operations).” Gartner Glossary, 2016. [Online]. Available: <https://web.archive.org/web/20260214203554/https://www.gartner.com/en/information-technology/glossary/aiops-artificial-intelligence-operations>.
- [58] S. Newman, *Building microservices: designing fine-grained systems*. O’Reilly Media, Inc., 2015.